

《机器学习》各章总结

第 1 章 绪论 总结

简述机器学习的发展历程，及应用现状。介绍在机器学习领域做出突出贡献的企业和人物，以及我国在机器学习领域所取得的领先地位。

- (1) 杭州科技“六小龙”企业；
- (2) 机器学习可以解决什么问题；
- (3) 机器学习的类型有哪些；
- (4) 机器学习的一般步骤；

第 2 章 模型评估与选择 总结

机器学习得到的模型不仅对已知数据而且对未知数据都能有很好的预测能力，不同学习方法会给出不同的模型。当损失函数给定时，基于损失函数的模型的训练误差和模型的测试误差就自然称为学习方法评估的标准。

- (1) 什么是模型的评估，评估的方法有哪些？；
- (2) 了解模型的欠拟合、过拟合；
- (3) 掌握模型的泛化误差和经验误差；
- (4) 掌握模型的性能度量：查准率、查全率、正确率；

第 3 章 K-近邻 总结

KNN 模型的核心思想很简单，即近朱者赤、近墨者黑。工作机制非常简单：它通过将每一个测试集样本点与训练集中每一个样本之间测算欧氏距离，然后取欧氏距离最近的 K 个点 (k 是可以人为划定的近邻取舍个数，K 的确定会影响算法结果)，并统计这 K 个训练集样本点所属类别频数，将其中频数最高的所属类别化为该测试样本点的预测类别。

- (1) 了解 K-近邻是懒惰学习算法；
- (2) 了解 KNN 算法的思想；
- (3) 参数 K：1-近邻法还是 K-近邻；K 值的选择问题；
- (4) 距离向量：欧氏距离、曼哈顿距离、切比雪夫距离。

第 4 章 线性模型 总结

- (1) 掌握分类和回归的区别；
- (2) 线性回归、最小二乘法、线性回归中的均方误差；
- (3) 掌握线性判别函数的基本概念，包括：两类问题线性判别函数的一般表达式、准则函数的定义、权向量和决策面之间的关系、判别函数的几何意义等；
- (4) 掌握 Fisher 线性判别准则的基本原理、Fisher 准则函数的定义、Fisher 算法实现步骤；
- (5) 逻辑回归与线性回归；
- (6) 对数回归及其求解函数。

第 5 章 支持向量机 总结

支持向量机 (Support Vector Machine, SVM) 是一类按监督学习 (supervised learning) 方式对数据进行二元分类的广义线性分类器 (generalized linear classifier)，其决策边界是对学习样本求解的最大边距超平面 (maximum-margin hyperplane)。支持向量机 (Support Vector Machine, SVM) 的基本模型是在特征空间上找到最佳的分离超平面使得训练集上正负样本

间隔最大。

- (1) 间隔与支持向量;
- (2) 软间隔、硬间隔和非线性 SVM

第 6 章 决策树 总结

决策树是一种特殊的树形结构，一般由节点和有向边组成。其中，节点表示特征、属性或者一个类，而有向边包含判断条件。决策树从根节点开始延伸，经过不同的判断条件后，到达不同的子节点。而上层子节点又可以作为父节点被进一步划分为下层子节点。一般情况下，我们从根节点输入数据，经过多次判断后，这些数据就会被分为不同的类别。这就构成了一颗简单的分类决策树。

- (1) 掌握信息熵和信息增益的计算;
- (2) 掌握特征的选择和决策树的生成;
- (3) 了解决策树的预剪枝和后剪枝。

第 7 章 贝叶斯 总结

贝叶斯分类决策是统计决策理论中的一个基本方法，这个方法进行分类时要求各类别总体的概率分布是已知的，并且分类的类别数是一定的。在类条件概率密度和先验概率已知的情况下，通过贝叶斯公式比较样本属于两类的后验概率，将类别决策为后验概率大的一类，这样做的目的是使总体错误率最小。

- (1) 理解先验概率、条件概率和后验概率;
- (2) 掌握最小错误率的贝叶斯决策;
- (3) 掌握最小风险的贝叶斯决策;
- (4) 理解朴素贝叶斯的“朴素”原理;
- (5) 理解拉普拉斯修正解决“零概率”问题;
- (6) 掌握朴素贝叶斯决策。

第 8 章 集成学习 总结

集成学习 (Ensemble Learning) 是一种经典的机器学习范式，它的核心思想是“三个臭皮匠顶个诸葛亮”，即通过结合多个单模型（通常叫做“弱学习器”或“基学习器”）的决策来弥补单个模型的不足，从而得到一个更加强大和准确的学习系统。

- (1) 理解集成算法的原理，三个臭皮匠，胜过诸葛亮!;
- (2) 理解个体与集成，并行与串行;
- (3) 理解随机森林与 Bagging 算法;
- (4) 理解 Boosting 算法的原理，如何让优秀的分类器占整体的权值更高，而差的分类器权值更低。

第 9 章 聚类 总结

将数据样本划分为若干个通常不相交的“簇” (cluster)，既可以作为一个单独的过程（用于寻找数据内在的分布结构），也可作为分类其他学习任务的前驱过程。指将样本分到不同的组中使得同一组中的样本差异尽可能的小，而不同组中的样本差异尽可能的大。

- (1) 掌握聚类的三种方法：K-means 聚类、密度聚类、层次聚类
- (2) 误差平方和准则和离散度准则;
- (3) 掌握 K-means 均值算法的基本思想和步骤和初始划分方法;

- (4) 理解层次聚类的基本思想和步骤；
- (5) 理解密度聚类的基本思想和步骤。

第 10 章 推荐系统 总结

- (1) 掌握用户协同过滤算法；
- (2) 掌握物品协同过滤算法；
- (3) 利用过滤算法完成一个完整的推荐系统。