

第7章 贝叶斯分类器

浙江理工大学 曹丽

办公室 10-541

本节课学习指南


理解本章的关键：

- 要正确理解先验概率，类概率密度函数，后验概率这三种概率；
- 对这三种概率的定义，相互关系要搞得清清楚楚；
- 贝叶斯公式正是体现这三者关系的式子，要透彻掌握。

5.1 贝叶斯定理概述

⑩ 贝叶斯，英国数学家。1702年出生在伦敦，做过神甫。1742年成为英国皇家学会会员。1763年4月7日逝世。

⑩ 贝叶斯在数学方面主要研究概率论。他首先将归纳推理法用于概率论基础理论，并创立了贝叶斯统计理论，对于统计决策函数、统计推断、统计的估算等做出了贡献。



5.1 贝叶斯定理概述

贝叶斯分类决策是统计决策理论中的一个基本方法，这个方法进行分类时要求各类别总体的概率分布是已知的，并且分类的类别数是一定的。

在类条件概率密度和先验概率已知的情况下，通过贝叶斯公式比较样本属于两类的后验概率，将类别决策为后验概率大的一类，这样做的目的是使总体错误率最小。

5.1 贝叶斯定理概述

贝叶斯定理：是关于随机事件 A 和 B 的条件概率的计算公式。

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

$P(A)$ 是 A 的先验概率，之所以称为“先验”是因为它不考虑任何 B 方面的因素；

$P(B)$ 是 B 的先验概率，也称为标准化常量

$P(A|B)$ 是已知 B 发生后 A 的条件概率，也由于得自 B 的取值而被称作 A 的后验概率

$P(B|A)$ 是已知 A 发生后 B 的条件概率，也由于得自 A 的取值而被称作为 B 的后验概率

贝叶斯定理：在 B 出现的前提下事件 A 发生的概率，等于 A 出现的前提下事件 B 发生的概率，乘以事件 A 单独发生的概率，再除以事件 B 单独发生的概率。


6.1 贝叶斯定理概述

条件概率：

若是 Ω 全集， A 、 B 是其中的事件（子集）， P 表示事件发生的概率，则

$$P(A|B) = \frac{P(AB)}{P(B)}$$

为事件 B 发生后 A 发生的概率，其中 $P(AB)$ 表示两件事情共同发生的概率。



5.1 贝叶斯定理概述

假设一个盒子里装了6只球，其中绿色球2只，红色球4只，**每次不放回**随机从盒子里面取出一只球。求连续2次取到红球的概率。

假设第一次取到红球表示事件A，第二次取到红球表示事件B，则连续两次取到红球的概率即 $P(AB)$ ，事件A发生的概率为 $P(A) = 4/6$ ，在第一次取到红球事件A发生的条件下，第二次取到红球的条件概率为

$$P(B|A) = 3/5$$

使用条件概率公式，连续两次取到红球的概率为


$$P(AB) = P(B|A) P(A) = 3/5 \times 4/6 = 0.4$$

5.1 贝叶斯定理概述

全概率：

设 Ω 为试验E的样本空间，A为E的事件， $B_1, B_2, \dots, B_n$ 为 Ω 的一个划分，且 $P(B_i) > 0 (i = 1, 2, \dots, n)$ ，则

$$\begin{aligned} P(A) &= P(A|B_1)P(B_1) + P(A|B_2)P(B_2) \cdots + P(A|B_n)P(B_n) \\ &= \sum_{i=1}^n P(B_i)P(P(A|B_i)) \end{aligned}$$



全概率公式的主要用途在于它可以将一个复杂事件的概率计算问题,分解为若干个简单事件的概率计算问题,最后应用概率的可加性求出最终结果.

5.1 贝叶斯定理概述

贝叶斯公式的应用：

我们把事件A看作是某一个过程的结果；

把 $B_1, B_2, \dots, B_n$ 看作是该过程的若干原因，每一个原因发生的概率 $P(B_n)$ 已知；

每个原因对结果的影响程度 $P(A|B_n)$ 已知；

如果已知事件A已经发生，要求此时是由第 i 个原因引起的概率 $P(B_i|A)$ ：

$$P(B_i|A) = \frac{P(B_i)P(A|B_i)}{\sum_{i=1}^n P(B_i)P(A|B_i)}$$

5.1 贝叶斯定理概述

例子：

某电子设备制作厂所用的元件是由三家元件制作厂提供的，根据以往的记录有以下数据：

元件制造厂	次品率	提供元件的份额
1	0.02	0.15
2	0.01	0.80
3	0.03	0.05

这三家工厂的产品在仓库里面是均匀混合的，且无区别的标志

- (1) 在仓库里面随机取一只元件，求它是次品的概率？
- (2) 在仓库里面随机取一只元件，若已知取到的次品，分析此次次品出自何厂，需求出此次品由三家工厂的概率分别是多少？试求这些概率。

5.1 贝叶斯定理概述

问题（1）：随机取一只次品，求它是次品的概率：

设 B_i ($i = 1, 2, 3$) 表示“所取到的产品是由第 i 家工厂提供的”

则 B_1, B_2, B_3 是样本空间 Ω 的一个分割

且 $P(B_1) = 0.15$, $P(B_2) = 0.80$, $P(B_3) = 0.05$

由全概率公式：

$$P(A) = P(B_1A \cup B_2A \cup B_3A)$$

$$= P(B_1)P(A|B_1) + P(B_2)P(A|B_2) + P(B_3)P(A|B_3)$$

$$= 0.15 \times 0.02 + 0.80 \times 0.01 + 0.05 \times 0.03$$

$$= 0.0125$$

5.1 贝叶斯定理概述

问题（2）：在仓库中随机取一只元件，若已取到的是次品，分析该次品出自何厂？

由贝叶斯公式得：

$$P(B_1|A) = \frac{P(A|B_1)P(B_1)}{P(A)} = \frac{0.15 \times 0.02}{0.0125} = 0.24$$

$$P(B_2|A) = 0.64$$

$$P(B_3|A) = 0.12$$

因此，该次品来自第2家工厂的可能性最大。

5.1 贝叶斯定理概述

事件A在事件B发生的条件下的概率，与事件B在事件A发生的条件下的概率是不一样的；然后这两者之间存在一定关系的，**贝叶斯**就是对于这种关系的描述。

结合实例具体说明贝叶斯定理：

患者信息表

症状	职业	疾病
打喷嚏	护士	感冒
打喷嚏	农夫	过敏
头痛	建筑工人	脑震荡
头痛	建筑工人	感冒
打喷嚏	教师	感冒
头痛	教师	感冒

现在又来了第7个患者，是一个打喷嚏的人。请问他所患疾病是感冒的概率有多大？

求解： $P(\text{感冒}|\text{打喷嚏})$

5.1 贝叶斯定理概述

患者信息表

症状	职业	疾病
打喷嚏	护士	感冒
打喷嚏	农夫	过敏
头痛	建筑工人	脑震荡
头痛	建筑工人	感冒
打喷嚏	教师	感冒
头痛	教师	感冒

如果想要知道患感冒的人打喷嚏的概率，
在已知患感冒条件下打喷嚏的概率。

$$P(\text{打喷嚏}|\text{感冒}) = \frac{P(\text{打喷嚏} \cap \text{感冒})}{P(\text{感冒})} = \frac{2/6}{4/6} = \frac{1}{2}$$

根据贝叶斯定理：

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

可以计算得到：打喷嚏的人患上感冒的概率：

$$P(\text{感冒}|\text{打喷嚏}) = \frac{P(\text{打喷嚏}|\text{感冒})P(\text{感冒})}{P(\text{打喷嚏})} = \frac{\frac{1}{2} \times \frac{4}{6}}{\frac{3}{6}} = \frac{2}{3}$$

5.2 贝叶斯分类

贝叶斯分类实质：

贝叶斯（Bayes）决策是统计决策理论中的一个基本方法，这个方法进行分类时要求各类别总体的概率分布是已知的，并且分类的类别数是一定的。其对部分未知的状态用主观概率估计，用贝叶斯公式进行修正，最后利用期望值和修正概率做出最优决策。

5.2 贝叶斯分类

贝叶斯分类实质：

- **先验概率**泛指一类事物发生的概率，通常根据历史资料或主观判断，未经实验证实所确定的概率。
- 而**后验概率**涉及的是某个特定条件下，得到信息后，一个具体的事物发生的概率。

先验概率与后验概率的关系

The diagram illustrates the relationship between prior and posterior probabilities using Bayes' formula. The formula is enclosed in a red rectangular box. Inside the box, the term $P(A_i|B)$ is circled in blue. A blue arrow points from this circled term to the label '后验概率' (Posterior Probability) located outside the box to the left. Above the box, a purple arrow points from the term $P(A_i)$ in the numerator to the label '先验概率' (Prior Probability). Below the box, a red double-lined arrow points downwards to the label '贝叶斯公式' (Bayes' Formula).

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{\sum_{j=1}^n P(A_j)P(B|A_j)}$$

贝叶斯公式的**实质**：通过观察**B**把状态的先验概率转化为状态的后验概率；判断后验概率值后，得出分类决策。

5.2 贝叶斯分类

- (1) 先验概率 $P(c)$ 是指根据之前的知识和经验得出 c_i 类样本出现的概率；
- (2) 后验概率 $P(c_i|x)$ 与先验概率相对应，指收到数据 x 后，根据这批样本提供的信息统计的 c_i 出现的概率，表明样本 x 属于 c_i 类的概率；
- (3) 条件概率 $P(x|c_i)$ 是指属于 c_i 类的样本 x 发生某种事件的概率，也称为类概率密度函数，在统计学中称为似然函数。

贝叶斯 (Bayes) 决策适合以下场合

- (1) 样本数量不充分多，类别总数已知；
- (2) 在试验之前已有先验信息，各类参考样本的概率分布是已知的，即每类参考样本出现的先验概率是各类概率密度函数。

5.2 贝叶斯分类—最小错误率的贝叶斯分类

- 在模式分类的问题中，从尽量减少错误的角度出发，利用贝叶斯公式得出使错误最小分类原则
- 以癌细胞识别的例子引出贝叶斯决策

5.2 最小错误率的贝叶斯分类

- 癌细胞识别，两类别问题——细胞正常与异常
- 若仅利用先验概率进行分类
 - 统计的角度得出的两类细胞出现的概率
 - 无法实现正常与异常细胞的分类目的
- 先验概率提供的信息太少，要结合样本观测信息，为此需要利用类条件概率

5.2 最小错误率的贝叶斯分类

癌细胞识别：

设每个要识别的细胞已作过预处理，抽取 d 个特征描述量，成为一个 d 维特征向量 X ，识别的目的是依据 X 将细胞分类为正常或异常。

用 ω_i ($i=1, 2$) 表示状态， ω_1 表示正常， ω_2 表示异常。


设根据医院细胞病理检查的大量统计资料可以对某一地区正常细胞和异常细胞出现的比例作出估计，即识别前已知正常状态的先验概率 $P(\omega_1)$ 和异常状态的先验概率 $P(\omega_2)$ 。

$$P(\omega_1) = 0.9 \quad P(\omega_2) = 0.1 \quad P(\omega_1) + P(\omega_2) = 1$$

5.2 最小错误率的贝叶斯分类

癌细胞识别：

如果只按照先验概率进行决，由于 $P(\omega_1) > P(\omega_2)$ ，所有细胞都会划归为 ω_1 类，即为正常细胞，不可能达到将正常细胞与异常细胞区分开的目的。



现有一待识别细胞，其观测值为 x_0 ，从类条件概率密度曲线上查得：

$$p(x_0 | \omega_1) = 0.2$$

$$p(x_0 | \omega_2) = 0.4$$

试对该细胞进行分类。

5.2 最小错误率的贝叶斯分类

癌细胞识别：

$$p(\omega_i|X) = \frac{p(X|\omega_i)P(\omega_i)}{\sum_{j=1}^c p(X|\omega_j)P(\omega_j)}$$


$$p(\omega_1|x) = \frac{p(x|\omega_1)P(\omega_1)}{\sum_{j=1,2} p(x|\omega_j)P(\omega_j)} = \frac{0.2 \times 0.9}{0.2 \times 0.9 + 0.4 \times 0.1} = 0.818$$

$$p(\omega_2|x) = 1 - p(\omega_1|x) = 1 - 0.818 = 0.182$$

$$\because p(\omega_1|x) > p(\omega_2|x)$$

$\therefore x \in \omega_1$ 较合理，即为正常细胞

5.2 最小错误率的贝叶斯分类



细胞识别后验概率

贝叶斯公式的实质：通过观察 x 把状态的先验概率转化为状态的后验概率；
判断后验概率值后，得出分类决策。

5.2 最小错误率的贝叶斯分类

□ 两类问题的最小错误率Bayes决策规则

- ◆ 一维情况下，两类问题的最小错误率贝叶斯决策规则：

$$\text{if } p(\omega_1|x) > p(\omega_2|x) \quad x \in \omega_1 \quad \text{else } x \in \omega_2$$

- ◆ 多维情况下，两类问题的最小错误率贝叶斯决策规则：

$$\text{if } p(\omega_1|X) > p(\omega_2|X) \quad X \in \omega_1 \quad \text{else } X \in \omega_2$$

5.2 最小错误率的贝叶斯分类

□ 两类问题的最小错误率Bayes决策规则

规则的四种等价形式：（由贝叶斯公式推导）

$$1. \text{ if } p(\omega_i|X) = \max_{j=1,c} p(\omega_j|X) \quad X \in \omega_i$$

$$2. \text{ if } p(X|\omega_i)P(\omega_i) = \max_{j=1,c} p(X|\omega_j)P(\omega_j) \quad X \in \omega_i$$

$$3. \text{ if } l(X) = \frac{p(X|\omega_1)}{p(X|\omega_2)} > \frac{P(\omega_2)}{P(\omega_1)} \quad X \in \omega_1$$

似然比

$$4. \text{ if } h(X) = -\ln[l(X)] = -\ln \left[\frac{p(X|\omega_1)}{p(X|\omega_2)} \right] < \ln \left[\frac{P(\omega_2)}{P(\omega_1)} \right] \quad X \in \omega_1$$

5.2 最小错误率的贝叶斯分类

□ 错误率

这样的决策可以使分类错误率最小，因此称为**最小错误率贝叶斯决策**。

错误率为平均错误概率：指将应属于某一类的模式错分到其他类的概率，表示为：

$$P(e) = \int_{-\infty}^{+\infty} p(e|x) P(x) dx$$

$$p(e|x) = \begin{cases} p(\omega_2|x) & x \in \omega_1 \\ p(\omega_1|x) & x \in \omega_2 \end{cases}$$


$$P(e) = \int_{-\infty}^t p(\omega_2|x) P(x) dx + \int_t^{+\infty} p(\omega_1|x) P(x) dx$$

5.2 最小错误率的贝叶斯分类

□ 错误率

对于两类问题，设 R_1 和 R_2 分别是 ω_1 和 ω_2 类别的判决区域，所有可能发生的错误为将来自 ω_1 类的样本错分到 ω_2 类中，以及将来自 ω_2 类的样本错分到 ω_1 类中。**错误率表示为两种错误之和**，如下式和下图所示，图中是斜线面积和交叉线面积。

$$\begin{aligned} P(e) &= \int_{-\infty}^t p(x|\omega_2)P(\omega_2)dx + \int_t^{+\infty} p(x|\omega_1)P(\omega_1)dx \\ &= P(\omega_2) \int_{-\infty}^t p(x|\omega_2)dx + P(\omega_1) \int_t^{+\infty} p(x|\omega_1)dx \end{aligned}$$



5.2 最小错误率的贝叶斯分类

最小错误率决策练习:

这两个公式大家应该都比较熟悉，这里举个例子：已知：某个商店里的顾客中男性与女性的比例为2：1，男性购买商品的概率为1/2，而女性购买商品的概率为2/3。问题：假如有一个顾客在商店里买了商品，请问他的性别为男性或女性的概率分别是多少？

本题就是典型的某个事情被观测到了，求它属于某一类的概率。即为后验概率，后面再来介绍什么是先验概率和后验概率。

设：x_1 = 购买商品，x_2 = 不购买商品，y_1 = 男性，y_2 = 女性

由题意可得：

$$\text{先验概率} \quad p(y_1) = \frac{2}{3}, p(y_2) = \frac{1}{3}$$

$$\text{类条件概率} \quad p(x_1|y_1) = \frac{1}{2}, p(x_2|y_1) = \frac{1}{2}, p(x_1|y_2) = \frac{2}{3}, p(x_2|y_2) = \frac{1}{3}$$

5.2 最小错误率的贝叶斯分类

最小错误率决策练习:

假设男性和女性购买商品是相互独立的，可以由全概率公式计算 $p(x_1)$:

$$p(x_1) = p(x_1|y_1)p(y_1) + p(x_1|y_2)p(y_2) = \frac{5}{9}$$

根据贝叶斯公式可以计算出:

$$p(y_1|x_1) = \frac{p(x_1|y_1)p(y_1)}{p(x_1)} = \frac{1/2 \times 2/3}{5/9} = \frac{3}{5}$$

$$p(y_2|x_1) = \frac{p(x_1|y_2)p(y_2)}{p(x_1)} = \frac{2/3 \times 1/3}{5/9} = \frac{2}{5}$$

所以，如果这个人购买了商品，那么他是男性的概率为3/5。

5.3 最小风险的贝叶斯分类

在模式分类的决策中，使错误率达到最小是最重要的。

但在实际情况中有时必须考虑一个比错误率更为广泛的概念——**风险**，如：投资、买彩票、癌细胞识别等应用场合，而风险又与损失相关。

5.3 最小风险的贝叶斯分类

损失函数 $\lambda(\alpha_i, \omega_j)$

$\lambda(\alpha_i, \omega_j) \quad i=1, 2, \dots, a; j=1, 2, \dots, c$

- 当真实状态为 ω_j 而采取的决策为 α_i 时所带来的损失。
- 所有的损失函数构成一般决策表。

注意：

- ✓ 在决策论中，对分类问题所作的判决，称之为决策，记为 α_i 。
- ✓ 所有决策组成的空间称为决策空间。
- ✓ 决策不仅包括根据观测值将样本划归哪一类，还可包括其它决策，如“拒绝”，因此决策空间内决策总数 a 可以不等于类别数 c

5.3 最小风险的贝叶斯分类

条件期望损失（条件风险） $R(\alpha_i|X)$

□ 反映了对某一 X 采取决策 α_i 所带来的风险。

$$R(\alpha_i|X) = E[\lambda(\alpha_i, \omega_j)] = \sum_{j=1}^c \lambda(\alpha_i, \omega_j) p(\omega_j|X), \quad i = 1, 2, \dots, a$$

注意：

- 不同的 X ，采取决策 α_i 时， $R(\alpha_i|X)$ 的大小是不同的。因此，可以把决策看成是 X 的函数，即： $\alpha(X)$ 。
- 此时， $R(\alpha_i|X)$ 又可记为： $R(\alpha(X)|X)$

5.3 最小风险的贝叶斯分类

- 由于期望风险是条件风险在整个特征空间的积分，因此如果对每个决策，使其条件风险最小，那么此时的期望风险也必然最小。

$$R = \int R[\alpha(X)|X] P(X) dX$$

- 最小风险贝叶斯决策规则：

$$\text{if } R(\alpha_k|X) = \min_{i=1, \dots, a} R(\alpha_i|X) \quad \alpha = \alpha_k$$

5.3 最小风险的贝叶斯分类

例题5.2：癌细胞识别

在例5.1给出的条件基础上，利用以下决策表，按最小风险贝叶斯决策进行分类。

$\lambda(\alpha_i, \omega_j)$ ：当细胞的真实状态是 ω_j ，但将其分类为 α_i 时，带来的损失。

$\lambda(\alpha_i, \omega_j)$ 损失 \ 状态	ω_1	ω_2
α_1	0	6
α_2	1	0

解：根据例2.1和决策表，得到以下已知条件：

$$P(\omega_1)=0.9, \quad p(x|\omega_1)=0.2, \quad \lambda_{11}=0, \quad \lambda_{12}=6$$

$$P(\omega_2)=0.1, \quad p(x|\omega_2)=0.4, \quad \lambda_{21}=1, \quad \lambda_{22}=0$$

6.3 最小风险的贝叶斯分类

最小风险贝叶斯决策步骤

1. 已知: $P(\omega_j)$, $p(X|\omega_j)$, $j=1, 2, \dots, c$, 待识别的 X ;

2. 根据贝叶斯公式计算出后验概率;

$$p(\omega_i|X) = \frac{p(X|\omega_i)P(\omega_i)}{\sum_{j=1}^c p(X|\omega_j)P(\omega_j)}$$

3. 用计算出的后验概率及决策表, 计算 α_i ($i=1, 2, \dots, a$) 的条件风险;

$$R(\alpha_i|X) = \sum_{j=1}^c \lambda(\alpha_i, \omega_j) p(\omega_j|X), \quad i=1, 2, \dots, a$$

4. 对(3)中得到的 a 个条件风险值 $R(\alpha_i|X)$ ($i=1, 2, \dots, a$) 进行比较, 找出使条件风险最小的决策 α_k , 则 α_k 就是最小风险贝叶斯决策。

$$R(\alpha_k|X) = \min_{i=1, \dots, a} R(\alpha_i|X) \quad \alpha = \alpha_k$$

5.3 最小风险的贝叶斯分类

最小错误率和最小风险决策间关系

□ 设损失函数为：

$$\lambda(\alpha_i, \omega_j) = \begin{cases} 1 & i \neq j \\ 0 & i = j \end{cases} \quad i, j = 1, 2, \dots, c$$

- 正确决策时没有损失，任何错误决策的损失均为1。
- 称为0-1损失函数。

□ 0-1损失函数下，条件风险为：

$$R(\alpha_i | X) = \sum_{j=1}^c \lambda(\alpha_i, \omega_j) p(\omega_j | X) = \sum_{\substack{j=1 \\ j \neq i}}^c p(\omega_j | X)$$

对X采取决策 α_i 的
条件错误概率



5.3 最小风险的贝叶斯分类

最小错误率和最小风险决策间关系

最小风险贝叶斯决策： $R(\alpha_k | x) = \min_{i=1, \dots, a} R(\alpha_i | x) \quad \alpha = \alpha_k$

$$R(\alpha_i | X) = \sum_{\substack{j=1 \\ j \neq i}}^c p(\omega_j | X)$$
$$p(\omega_i | X) + \sum_{\substack{j=1 \\ j \neq i}}^c p(\omega_j | X) = 1$$



$$\sum_{\substack{j=1 \\ j \neq k}}^c p(\omega_j | X) = \min_{i=1, \dots, a} \sum_{\substack{j=1 \\ j \neq i}}^c p(\omega_j | X)$$
$$\Downarrow$$
$$p(\omega_k | X) = \max_{i=1, \dots, a} p(\omega_i | X)$$

结论：0-1损失函数下，最小错误率贝叶斯决策是最小风险贝叶斯决策的特例。

5.3 朴素贝叶斯分类器

朴素贝叶斯算法是统计学的一种分类方法，它利用**概率统计知识**进行分类。朴素贝叶斯以贝叶斯定理为基础，故统称为贝叶斯分类。之所以有“朴素”两个字，是因为该算法假设特征之间相互独立，而这个假设看上去有点“过头”（因为绝大多数实际问题不太可能存在完全的独立性），因此加上了朴素二字。

5.3 朴素贝叶斯分类器

朴素贝叶斯： 它是一种简单但极为强大的预测建模算法。之所以称为“**朴素的**”，是因为它假设每个输入变量是独立的。这是一个**强硬的假设**，实际情况并不一定，但是这项技术对于绝大部分的复杂问题仍然非常有效。朴素贝叶斯分类是常用的贝叶斯分类方法。

我们日常生活中看到一个陌生人，要做的第一件事情就是判断 TA 的性别，判断性别的过程就是一个分类的过程。根据以往的经验，我们通常会从身高、体重、鞋码、头发长短、服饰、声音等角度进行判断。**这里的“经验”就是一个训练好的关于性别判断的模型**，其训练数据是日常中遇到的各式各样的人，以及这些人实际的性别数据。

5.3 朴素贝叶斯分类器

朴素贝叶斯分类器（naïve bayes classifier, NBC）是一种常见且简单有效的贝叶斯分类算法。对已知类别，朴素贝叶斯分类器在估计类条件概率时假设特征之间条件独立。这样的假设，可以使得有限的训练样本下，原本难以计算的联合概率 $P(X_1, X_2, \dots, X_n|Y)$ 转化为每个类别条件概率的乘积。尤其是在特征很多时，就显得更加简便。

$$P(X|Y = y) = \prod_{i=1}^n P(X_i|Y = y)$$

其中，每个特征集 $X = \{X_1, X_2, \dots, X_n\}$ 包含 n 个特征。

5.3 朴素贝叶斯分类器

条件独立性

给定 X, Y 条件独立，则有：

$$P(X, Y|Z) = P(X|Z) \times P(Y|Z)$$

有了条件独立假设，就不必计算 X 的每一个组合的类条件概率，只需要对给定的 Y ，计算每一个 X 的条件概率。显然这种方法更实用，因为它不需要很大的训练集就能获得较好的概率估计。如果没有这个条件，我们计算类条件概率密度就需要遍历计算所有不同的条件组合，需要大量样本支持。

5.3 朴素贝叶斯分类器

贝叶斯计算过程

假设某个体有 n 项特征，分别为 $X_1, X_2, \dots, X_n$ 。现有 m 个类别，分别为 $C_1, C_2, \dots, C_m$ 。

首先，朴素贝叶斯分类器计算每个类别的后验概率：

$$\begin{aligned} P(C_i | X_1, X_2, \dots, X_n) &= \frac{P(X_1 X_2 \dots X_n | C_i) P(C_i)}{P(X_1 X_2 \dots X_n)} \\ &= \frac{P(X_1 | C_i) P(X_2 | C_i) \dots P(X_n | C_i) P(C_i)}{P(X_1 X_2 \dots X_n)} \\ i &= 1, 2, \dots, m \end{aligned}$$

然后，比较独立特征的条件概率，将概率最大的那个类别，作为该样本的类别：

$$P(C_k | X_1 X_2 \dots X_n)$$

5.3 朴素贝叶斯分类器

例子1：现在要计算一个有头疼的建筑工人患感冒的概率：

$$P(\text{感冒}|\text{头痛} \cap \text{建筑工人}) = \frac{P(\text{头痛} \cap \text{建筑工人}|\text{感冒})P(\text{感冒})}{P(\text{头痛} \cap \text{建筑工人})}$$

根据朴素贝叶斯特征独立的假设，“头疼”和“建筑工人”两个特征是独立的，因此上面的等式可以转化为：

$$\begin{aligned} P(\text{感冒}|\text{头痛} \cap \text{建筑工人}) &= \frac{P(\text{头痛}|\text{感冒})P(\text{建筑工人}|\text{感冒})P(\text{感冒})}{P(\text{头痛} \cap \text{建筑工人})} \\ &= \frac{\frac{1}{2} \times \frac{1}{4} \times \frac{4}{6}}{\frac{1}{3}} = \frac{1}{4} \end{aligned}$$

因此，这个头痛的建筑工人，有25%的概率是得了感冒，同理，可以计算这个患者患上过敏或者脑震荡的概率。比价这个概率，就可以知道他最可能得什么病。

6.3 朴素贝叶斯分类器

在前述病患的实例中，我们要计算打喷嚏的建筑工人患过敏的概率：

$$P(\text{过敏}|\text{打喷嚏} \cap \text{建筑工人}) =$$

$$\frac{P(\text{打喷嚏}|\text{患过敏})P(\text{建筑工人}|\text{患过敏})P(\text{患过敏})}{P(\text{打喷嚏} \cap \text{建筑工人})} = \frac{1 \times 0 \times \frac{1}{6}}{\frac{1}{6}} = 0$$

由于我们所使用的实例数据量实在太小，缺少患过敏的建筑工人的样本，所以在计算条件概率的时候就会出现这样的情况。条件概率为0的值将导致该类别的后验概率直接为0，从而否定了其他特征对样本分类概率的估计，使得分类结果产生偏差。事实上，这种情况的出现，往往是由于我们的样本太少，从而缺少概率较低实践的数据，并非这个事件从来不会发生。

5.3 朴素贝叶斯分类器

拉普拉斯修正：

为了解决零概率的问题，法国数学家拉普拉斯最早提出用加1的方法估计没有出现过的现象的概率，这就是拉普拉斯修正。当数据量很大时，每个分量的计数加1造成的估计概率变化可以忽略不计，这样就可以方便有效地保证每一类中每个特征发生的概率是非零的。在实际使用中，拉普拉斯修正增加的数值可以设置为任何一个值，通常加 λ ($0 < \lambda < 1$) 来代替简单加1。同时如果对 n 个计数都加上 λ ，这时分母也要加上 $N \times \lambda$ 来保证所有类的概率加和为1。

5.3 朴素贝叶斯分类器

例子2：打网球的决定

No.	天气	气温	湿度	风	类别
1	晴	热	高	无	N
2	晴	热	高	有	N
3	多云	热	高	无	P
4	雨	适中	高	无	P
5	雨	冷	正常	无	P
6	雨	冷	正常	有	N
7	多云	冷	正常	有	P

No.	天气	气温	湿度	风	类别
8	晴	适中	高	无	N
9	晴	冷	正常	无	P
10	雨	适中	正常	无	P
11	晴	适中	正常	有	P
12	多云	适中	高	有	P
13	多云	热	正常	无	P
14	雨	适中	高	有	N

对下面的情况做出决策：

天气	温度	湿度	有风	打网球
晴	凉	高	是	?

5.3 朴素贝叶斯分类器

例子2：打网球的决定

No.	天气	气温	湿度	风	类别
1	晴	热	高	无	<i>N</i>
2	晴	热	高	有	<i>N</i>
3	多云	热	高	无	<i>P</i>
4	雨	适中	高	无	<i>P</i>
5	雨	冷	正常	无	<i>P</i>
6	雨	冷	正常	有	<i>N</i>
7	多云	冷	正常	有	<i>P</i>

No.	天气	气温	湿度	风	类别
8	晴	适中	高	无	<i>N</i>
9	晴	冷	正常	无	<i>P</i>
10	雨	适中	正常	无	<i>P</i>
11	晴	适中	正常	有	<i>P</i>
12	多云	适中	高	有	<i>P</i>
13	多云	热	正常	无	<i>P</i>
14	雨	适中	高	有	<i>N</i>

⑩ 统计结果

天气		温度			湿度		有风		打网球	
P	N	P	N		P	N	P	N	P	N
晴 2/9	3/5	热 2/9	2/5		高 3/9	4/5	否 6/9	2/5	9/14	5/14
云 4/9	0/5	暖 4/9	2/5		正常 6/9	1/5	是 3/9	3/5		
雨 3/9	2/5	凉 3/9	1/5							

5.3 朴素贝叶斯分类器

⑩ 统计结果

天气 E1		温度 E2		湿度 E3		有风 E4		打网球	
P	N	P	N	P	N	P	N	P	N
晴 2/9	3/5	热 2/9	2/5	高 3/9	4/5	否 6/9	2/5	9/14	5/14
云 4/9	0/5	暖 4/9	2/5	正常 6/9	1/5	是 3/9	3/5		
雨 3/9	2/5	凉 3/9	1/5						

⑩ 对下面的情况做出决策：

天气	温度	湿度	有风	打网球
晴	凉	高	是	?

5.3 朴素贝叶斯分类器

统计结果

天气 E1		温度 E2		湿度 E3		有风 E4		打网球 D	
P	N	P	N	P	N	P	N	P	N
晴 2/9	3/5	热 2/9	2/5	高 3/9	4/5	否 6/9	2/5	9/14	5/14
云 4/9	0/5	暖 4/9	2/5	正常 6/9	1/5	是 3/9	3/5		
雨 3/9	2/5	凉 3/9	1/5						

对下面的情况做出决策：

天气	温度	湿度	有风	打网球
晴	凉	高	是	?

模型： $E = E_1 \cap E_2 \cap E_3 \cap E_4$

决策： $P(D=no|E) > P(D=yes|E)$

贝叶斯公式： $P(D|E) = \frac{P(DE)}{P(E)} = \frac{P(E|D)P(D)}{P(E)}$

E为第二个表中的
取值、分别计算
D=yes/no的概率

5.3 朴素贝叶斯分类器

天气 E1		温度 E2		湿度 E3		有风 E4		打网球 D	
P	N	P	N	P	N	P	N	P	N
晴 2/9	3/5	热 2/9	2/5	高 3/9	4/5	否 6/9	2/5	9/14	5/14
云 4/9	0/5	暖 4/9	2/5	正常 6/9	1/5	是 3/9	3/5		
雨 3/9	2/5	凉 3/9	1/5						

⑩ 对下面的情况做出决策：

天气	温度	湿度	有风	打网球
晴	凉	高	是	?

$$P(D|E) = \frac{P(DE)}{P(E)} = \frac{P(E|D)P(D)}{P(E)}$$

$$P(\text{yes}|E) = \frac{P(DE)}{P(E)} = \frac{P(E|D)P(D)}{P(E)}$$

$$= \frac{P(E_1 \cap E_2 \cap E_3 \cap E_4 | \text{yes})P(\text{yes})}{P(E)}$$

$$= \frac{P(E_1 | \text{yes})P(E_2 | \text{yes})P(E_3 | \text{yes})P(E_4 | \text{yes})P(\text{yes})}{P(E)}$$

$$P(\text{yes}|E) = \frac{\frac{2}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{9}{14}}{P(E)} = \frac{0.0053}{P(E)}$$

5.3 朴素贝叶斯分类器

⑩ 已经计算出:
$$P(yes | E) = \frac{\frac{2}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{3}{9} \times \frac{9}{14}}{P(E)} = \frac{0.0053}{P(E)}$$

⑩ 同理可计算:
$$P(no | E) = \frac{\frac{3}{5} \times \frac{1}{5} \times \frac{4}{5} \times \frac{3}{5} \times \frac{5}{14}}{P(E)} = \frac{0.0206}{P(E)}$$

⑩ 利用公式:
$$P(yes | E) + P(no | E) = 1$$

⑩ 最后得到:
$$P(yes | E) = 20.5\% \quad P(no | E) = 79.5\%$$

⑩ 决策:
$$P(yes | E) < P(no | E) \quad \text{不去打球}$$

5.3 朴素贝叶斯分类器

天气 E1		温度 E2		湿度 E3		有风 E4		打网球 D	
P	N	P	N	P	N	P	N	P	N
晴 2/9	3/5	热 2/9	2/5	高 3/9	5/5	否 6/9	2/5	9/14	5/14
云 4/9	0/5	暖 4/9	2/5	正常 6/9	0/5	是 3/9	3/5		
雨 3/9	2/5	凉 3/9	1/5						

⑩ 对下面的情况做出决策：

天气	温度	湿度	有风	打网球
云	凉	正常	是	?

5.3 朴素贝叶斯分类器

连续数据案例

实际生活中我们得到的是连续的数值，比如下面这组数据：

编号	身高 (CM)	体重 (斤)	鞋码 (欧码)	性别
1	183	164	45	男
2	182	170	44	男
3	178	160	43	男
4	175	140	40	男
5	160	88	35	女
6	165	100	37	女
7	163	110	38	女
8	168	120	39	女

那么如果给你一个新的数据，身高 180、体重 120，鞋码 41，请问该人是男是女呢？

5.3 朴素贝叶斯分类器

身高、体重、鞋码是连续变量，如何来计算条件概率？

例如：计算男性，身高是180，概率是多少？

——假设身高、体重、鞋码符合正态分布，通过训练样本计算出均值和方差，得到正态分布的密度函数，根据密度函数，把值代入，计算出某一点的密度函数的值。

```
In [1]: import math
def normpdf(x, mean, sd):
    var = float(sd)**2
    denom = (2*math.pi*var)**.5
    num = math.exp(-(float(x)-float(mean))**2/(2*var))
    return num/denom
```

```
In [4]: normpdf(180, 179.5, 3.697)
```

```
Out[4]: 0.1069273346989667
```

同理：我们可以计算出男性体重为120的概率，男性鞋码为41码的概率。

5.3 朴素贝叶斯分类器

同理 我们可以计算出：

男性体重为120的概率为0.000382324；

男性鞋码为41码的概率为0.1203041111。

$$\begin{aligned}P(A_1A_2A_3|C_1) &= P(A_1|C_1) P(A_2|C_1) P(A_3|C_1) \\&= 0.1069 * 0.000382324 * 0.1203041111 \\&= 4.9169e-6\end{aligned}$$

$$\begin{aligned}P(A_1A_2A_3|C_2) &= P(A_1|C_2) P(A_2|C_2) P(A_3|C_2) \\&= 0.0000147489 * 0.015354144 * 0.120306074 \\&= 2.7244e-9\end{aligned}$$

得出结论：分类为男性的概率**大于**分类为女性的概率。

5.3 朴素贝叶斯分类器

西瓜例题 讲解

我们根据一个西瓜的特征，来判断它是否是个好瓜。

表 4.3 西瓜数据集 3.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

5.3 朴素贝叶斯分类器

西瓜例题 讲解

首先根据数据，利用朴素贝叶斯算法训练一个分类器

表 4.3 西瓜数据集 3.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

5.3 朴素贝叶斯分类器

西瓜例题 讲解

判断？一个具有特征（色泽是青绿、根蒂是蜷缩、敲声是浊响、纹理是清晰、脐部是凹陷、触感是硬滑、密度=0.697、含糖率=0.460）的**测试样例瓜**是否为好瓜？

(1) 首先计算先验概率

$$P(\text{好瓜} = \text{是}) = \frac{8}{17} \approx 0.471$$

$$P(\text{好瓜} = \text{否}) = \frac{9}{17} \approx 0.529$$

5.3 朴素贝叶斯分类器

(2) 计算每个属性的条件概率

离散值计算：

$$P_{\text{青绿}|\text{是}} = P(\text{色泽} = \text{青绿} | \text{好瓜} = \text{是}) = \frac{3}{8} = 0.375,$$

$$P_{\text{青绿}|\text{否}} = P(\text{色泽} = \text{青绿} | \text{好瓜} = \text{否}) = \frac{3}{9} \approx 0.333,$$

$$P_{\text{蜷缩}|\text{是}} = P(\text{根蒂} = \text{蜷缩} | \text{好瓜} = \text{是}) = \frac{5}{8} = 0.375,$$

$$P_{\text{蜷缩}|\text{否}} = P(\text{根蒂} = \text{蜷缩} | \text{好瓜} = \text{否}) = \frac{3}{9} \approx 0.333,$$

$$P_{\text{浊响}|\text{是}} = P(\text{敲声} = \text{浊响} | \text{好瓜} = \text{是}) = \frac{6}{8} = 0.750,$$

$$P_{\text{浊响}|\text{否}} = P(\text{敲声} = \text{浊响} | \text{好瓜} = \text{否}) = \frac{4}{9} \approx 0.444,$$

$$P_{\text{清晰}|\text{是}} = P(\text{纹理} = \text{清晰} | \text{好瓜} = \text{是}) = \frac{7}{8} = 0.875,$$

$$P_{\text{清晰}|\text{否}} = P(\text{纹理} = \text{清晰} | \text{好瓜} = \text{否}) = \frac{2}{9} \approx 0.222,$$

$$P_{\text{凹陷}|\text{是}} = P(\text{脐部} = \text{凹陷} | \text{好瓜} = \text{是}) = \frac{6}{8} = 0.750,$$

$$P_{\text{凹陷}|\text{否}} = P(\text{脐部} = \text{凹陷} | \text{好瓜} = \text{否}) = \frac{2}{9} \approx 0.222,$$

$$P_{\text{硬滑}|\text{是}} = P(\text{触感} = \text{硬滑} | \text{好瓜} = \text{是}) = \frac{6}{8} = 0.750,$$

$$P_{\text{硬滑}|\text{否}} = P(\text{触感} = \text{硬滑} | \text{好瓜} = \text{否}) = \frac{6}{9} \approx 0.667,$$

5.3 朴素贝叶斯分类器

(2) 计算每个属性的条件概率

连续值计算:

$$\begin{aligned} p_{\text{密度: 0.697}|\text{是}} &= p(\text{密度} = 0.697 \mid \text{好瓜} = \text{是}) \\ &= \frac{1}{\sqrt{2\pi} \cdot 0.129} \exp\left(-\frac{(0.697 - 0.574)^2}{2 \cdot 0.129^2}\right) \approx 1.959, \end{aligned}$$

$$\begin{aligned} p_{\text{密度: 0.697}|\text{否}} &= p(\text{密度} = 0.697 \mid \text{好瓜} = \text{否}) \\ &= \frac{1}{\sqrt{2\pi} \cdot 0.195} \exp\left(-\frac{(0.697 - 0.496)^2}{2 \cdot 0.195^2}\right) \approx 1.203, \end{aligned}$$

$$\begin{aligned} p_{\text{含糖: 0.460}|\text{是}} &= p(\text{含糖率} = 0.460 \mid \text{好瓜} = \text{是}) \\ &= \frac{1}{\sqrt{2\pi} \cdot 0.101} \exp\left(-\frac{(0.460 - 0.279)^2}{2 \cdot 0.101^2}\right) \approx 0.788, \end{aligned}$$

$$\begin{aligned} p_{\text{含糖: 0.460}|\text{否}} &= p(\text{含糖率} = 0.460 \mid \text{好瓜} = \text{否}) \\ &= \frac{1}{\sqrt{2\pi} \cdot 0.108} \exp\left(-\frac{(0.460 - 0.154)^2}{2 \cdot 0.108^2}\right) \approx 0.066. \end{aligned}$$

5.3 朴素贝叶斯分类器

(3) 最后计算测试西瓜是好瓜的概率和坏瓜的概率？

$$\begin{aligned} &P(\text{好瓜} = \text{是}) \times P_{\text{青绿}|\text{是}} \times P_{\text{蜷缩}|\text{是}} \times P_{\text{浊响}|\text{是}} \times P_{\text{清晰}|\text{是}} \times P_{\text{凹陷}|\text{是}} \\ &\quad \times P_{\text{硬滑}|\text{是}} \times P_{\text{密度: 0.697}|\text{是}} \times P_{\text{含糖: 0.460}|\text{是}} \approx 0.038, \\ &P(\text{好瓜} = \text{否}) \times P_{\text{青绿}|\text{否}} \times P_{\text{蜷缩}|\text{否}} \times P_{\text{浊响}|\text{否}} \times P_{\text{清晰}|\text{否}} \times P_{\text{凹陷}|\text{否}} \\ &\quad \times P_{\text{硬滑}|\text{否}} \times P_{\text{密度: 0.697}|\text{否}} \times P_{\text{含糖: 0.460}|\text{否}} \approx 6.80 \times 10^{-5}. \end{aligned}$$

得出结论：好瓜的概率0.038远远大于坏瓜的概率 6.8×10^{-5}

分离器判定测试瓜为**好瓜**！

5.3 朴素贝叶斯分类器

西瓜例题讲解（拉普拉斯修正）

注意：若某个离散型的属性值在训练集中没有与某个类同时出现过，

当我们使用 $p(x_i|c) = \frac{|D_{c,x_i}|}{|D_c|}$

对其估计时， $p(x_i|c)$ 会等于0，但它其它的属性非常符合这个类型C的特征，在用最后的连乘式计算该样本属于该类的概率时，不管其他的属性如何取值，会因为 $p(x_i|c)$ 的这个零值导致分类器认为该样本属于这个类型的C的概率为0，显然这个是不合理的！

在上述好瓜训练中，好瓜样本中暂时没有具备特征敲声为清脆的样本，那么其计算出来的 $P_{\text{清脆}|\text{是}} = P(\text{敲声} = \text{清脆} | \text{好瓜} = \text{是}) = \frac{0}{8} = 0$

不管测试瓜为在其他属性上多么接近好瓜，都会判定为好瓜？**为什么？**

5.3 朴素贝叶斯分类器

具体做法是：令 N 表示训练集 D 中可能的类别数， N_i 表示第 i 个属性可能的取值数，那么我们估计类别概率值的 $P(c)$ 和离散属性条件概率的 $P(x_i|c)$ 的两个式子分别被调整为：

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N},$$

$$\hat{P}(x_i|c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i}$$

西瓜例题讲解 (进行平滑操作 拉普拉斯修正)

即，我们在分母上都加上取值的可能性个数，分子上都加1，这就保证了即使是存在某个属性 i 的取值 x_i 未曾与类别 c_i 同时出现过，我们也不会把其概率 $P(x_i|c)$ 算成0。

那么在上面的西瓜数据集中，使用拉普拉斯修正后，对于类别概率就有：

$$\hat{P}(\text{好瓜} = \text{是}) = \frac{8+1}{17+2} \approx 0.474, \quad \hat{P}(\text{好瓜} = \text{否}) = \frac{9+1}{17+2} \approx 0.526.$$

对于具备特征{敲声=清脆}的测试瓜就有：

同时，上文提到的概率 $P_{\text{清脆}|\text{是}}$ 可估计为

$$\hat{P}_{\text{清脆}|\text{是}} = \hat{P}(\text{敲声} = \text{清脆} | \text{好瓜} = \text{是}) = \frac{0+1}{8+3} \approx 0.091.$$

5.4 小结

贝叶斯分类优缺点：

优点

- (1) 分类效果稳健，特别适合于大规模数据集；
- (2) 能够很方便地处理多分类任务；
- (3) 对缺失数据和噪声数据都不敏感。

缺点

- (1) 特征之间相互独立的假设在实际应用中往往是不成立的，在特征个数比较多或者特征之间相关性较大时，分类效果一般；
- (2) 需要知道先验概率，且先验概率很多时候取决于假设，假设的模型可以有很多种，因此在某些时候会由于假设的先验模型的原因导致预测效果不佳；
- (3) 对输入数据的表达形式很敏感，应用在含有大量数值特征的数据集时并不理想。

5.4 小结

本章从贝叶斯定理开始，介绍了朴素贝叶斯算法在分类任务中的应用。作为一种简单的分类方法，朴素贝叶斯基于贝叶斯概率的基本思想，假设属性之间相互独立，即特征之间发生的概率互相不影响，这就是“朴素”两字的含义。虽然这个假设有些过头，但朴素贝叶斯方法的分类效果通常是很好。另外，为了解决训练集中条件概率为0导致无法计算后验概率的情况，我们引入拉普拉斯修正，通过在变量上随机增加一个 $0 \sim 1$ 的值来保证每一类的概率都不会为0。