

第2章 模型评估与选择

浙江理工大学 曹丽

办公室 10-541

模型的评估与选择

参考：(1) 周志华《机器学习》2.1 (2) 《统计学习方法2》1.4

为什么要进行模型评估

🍏 经验误差vs泛化误差

过拟合vs欠拟合

参考：(1) 周志华《机器学习》2.2-2.4 (2) 《统计学习方法2》1.5

什么是模型评估

评估方法(数据划分)

🍏 留出法

交叉验证法

自助法

🍏 性能度量(性能评估指标)

🍏 均方误差

错误率vs精度

查准率vs查全率

F1

🍏 ROC AUC

非均等代价

比较检验(如何比较数据)

测试性能不等于泛化性能

机器学习->概率近似正确


参考：(1) 周志华《机器学习》2.5

深入理解模型评估

🍏 偏差vs方差

过拟合vs欠拟合

典型的机器学习的过程



泛化能力强!

能很好地适用于 unseen instance

例如, 错误率低、精度高

然而, 我们手上没有 unseen instance,

为什么要进行模型评估

⑩ 什么是“错误率？”

⑩ 什么是“精度？”


⑩ 什么是“误差？”

➤ 学习器的实际预测输出与样本的真实输出之间的差异，称为“**误差**”。学习器在训练集上的误差称为“训练误差”或者“经验误差”，在新样本上的误差称为“泛化误差”。

⑩ 经验误差是否越小越好？

➤ NO！因为会出现“**过拟合**”！

经验误差 VS 泛化误差




泛化误差： 在“未来”样本上的误差

经验误差： 在训练集上的误差，亦称“训练误差”


泛化误差是越小越好；经验误差是否越小越好？

NO！因为会出现“**过拟合**”！


过拟合 VS 欠拟合



欠拟合



过拟合




正合适

过拟合 VS 欠拟合

过拟合

学习器把训练样本学习的“太好”，将训练样本本身的特点当做所有样本的一般性质，以至于把训练样本所包含的不太一般的特性都学到了，导致泛化性能下降。

这个问题不太好解决，有时候通过正则化的方法。




过拟合

过拟合 VS 欠拟合

欠拟合

学习能力底下而造成的，对训练样本的一般性质尚未学好。

这个问题是可以解决的，例如在后续课程中会讲到决策树模型，通过增加**决策树的分支**解决欠拟合出现的问题；通过神经网络深度学习，**增加训练的轮数**。



欠拟合

过拟合 VS 欠拟合

树叶训练样本



新样本



过拟合模型分类结果：
→ 不是树叶
(误以为树叶必须有锯齿)

欠拟合模型分类结果：
→ 是树叶
(误以为绿色的都是树叶)

https://blog.csdn.net/qq_15051123

评估的方法

⑩ 关键：怎么获得测试集？

⑩ 测试集应该与训练集“互斥”

⑩ 常见的方法

- 留出法

- 交叉验证法


- 自助法

数据集的划分

训练集：帮助我们训练模型，模型的迭代优化。
简单地说，就是通过**训练集的数据让我们确定拟合曲线的参数**；

验证集：用来**做模型选择**，即做模型的最终优化及确定的，用来辅助我们的模型的构建，调整超参数，即训练超参数，可选；

测试集：为了测试已经训练好的模型的精确度。




三者划分：训练集、验证集、测试集

机器学习：60%，20%，20%；70%，10%，20%

深度学习：98%，1%，1%（假设百万条数据）

留出法

拥有的数据集



注意：

- 保持数据分布一致性（例如：分层采样）
- 多次重复划分（例如：100次随机划分）
- 测试集不能太大、不能太小（例如：1/5~1/3）

留出法

数据集D划分为训练集S和测试集T 两个互斥集合。



训练/训练集划分要尽可能保持数据分布的一致性，避免因数据集划分过程中引入额外的偏差，而对最终结果产生影响。

例如，在分类任务中，采用分层采样，即尽量保持样本的类别比例相似，



e.g. 训练集S包含300个正例和300个反例；

测试集T包含100个正例和100个反例。


K-折交叉验证法




训练集




$\vdots$



测试集




→ 测试结果 1



→ 测试结果 2

$\vdots$



→ 测试结果 10

平均
返回
结果

K-折交叉验证法

1. 将数据集分层采样，划分为K个大小相似的互斥子集。

K常取 10。

2. 每次用 $k-1$ 个子集的并集作为训练集，余下的子集作为测试集

3. 将第2步的计算过程重复 p 次，最终返回 p 个测试结果的均值。

可以得到 p 个评估值。

评估结果的稳定性和保真性在很大程度上取决于 k 的取值。

K-折交叉验证法和留出法


留出法和交叉验证法**缺陷**:

保留一部分样本用于测试，实际评估模型所使用的训练集比D小，引入一些因训练样本规模不同，而导致的估计偏差。

自助法

基于“自助采样” (bootstrap sampling)

亦称“有放回采样”、“可重复采样”



约有36.8%的样本不出现

➤ 训练集与原样本集同规模

$$\Downarrow \quad \lim_{m \rightarrow \infty} \left(1 - \frac{1}{m}\right)^m \mapsto \frac{1}{e} \approx 0.368$$

“包外估计” (out of bag estimation)

自助法

以自助采样为基础，对含有 m 个样本的数据集 D 每次随机挑选一个样本**拷贝**到 D' ，重复 m 次，得到含有 m 个样本的**训练集** D' 。初始数据集 D 中约有**36.8%**的样本未出现在 D' 中。

$D \setminus D'$ 用作**测试集**。

实际模型与预期模型都使用 m 个训练样本，约有 $1/3$ 的样本没有在训练集中出现，且用于测试。这样的测试结果称为“**包外估计**”。

自助法

在数据集较小时，难以有效划分S和T是很有用。

“调参” 与最终模型

算法的参数：一般由人工设定，亦称“超参数”

模型的参数：一般由学习确定

调参过程相似：先产生若干模型，然后基于某种评估方法进行选择

参数调得好不好对性能往往对最终性能有关键影响

区别：训练集 VS. 测试集 VS. 验证集(validation set)

算法参数选定后，要用“训练集+验证集”重新训练最终模型

性能度量

⑩ 性能度量（performance measure）是衡量模型泛化能力的评价标准，反映了任务需求

⑩ 使用不同的性能度量往往会导致不同的评判结果

⑩ 什么样的模型是“好”的，不仅取决于算法和数据，还取决于任务的需求

性能度量

现实任务中，有多种学习算法供选择，同一个算法有多种参数配置；

理想的解决方案：

评估候选模型的泛化误差，选择泛化误差最小的那个模型；

现实中：

由于事先不知道**新样本**的特征，无法直接获得泛化误差，**无法得到泛化**误差小的学习器。

因此，我们只能从**训练样本**上尽可能学出适用于所有潜在样本的**普遍规律**，在遇到新样本时，才能做出正确的判别。

性能度量

我们努力使**经验误差**最小化，获得在**训练集**上表现很好的学习器。

同时，训练误差又由于**过拟合现象**的存在而不适合作为标准，那么，在现实中如何评估模型的**泛化性能**？

回归模型 评价指标

给定样例集

$D = \{(x^1, y^1), (x^2, y^2), \dots, (x^m, y^m)\}$, 评估学习器 f 的性能, 即把预测结果 $f(x)$ 和真实标记 y 进行比较。

误差: 样本真实输出与预测输出之间的差异;

训练(经验)误差: 训练集上;

泛化误差: 新样本上;

最常用的性能度量是 **“均方误差”**: $E(f: D) = \frac{1}{m} \sum_{i=1}^m (f(x_i) - y_i)^2$

分类模型 评价指标

正确肯定 (TP) : 预测为真, 实际为真

正确否定 (TN) : 预测为假, 实际为真

错误肯定 (FP) : 预测为真, 实际为假

错误否定 (FN) : 预测为假, 实际为假

查准率(Precision): $\text{Precision} = \frac{TP}{TP+FP}$

召回率 (Recall): $\text{Recall} = \frac{TP}{TP+FN}$

F-measure: $\frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$

正确率(Accuracy)= $\frac{TP+TN}{TP+TN+FP+FN}$

混淆矩阵 (confusion_matrix)

		预测值	
		Positive	Negative
实际值	Positive	TP	FN
	Negative	FP	TN

分类 评价指标

有100张照片，其中，猫的照片有60张，狗的照片是40张。

输入这个100张照片进行二分类识别，找出这100张照片中的所有的猫

识别结果的混淆矩阵

正例（Positives）：识别对的

负例（Negatives）：识别错的

		预测值	
		Positive	Negative
实际值	Positive	TP=40	FN=20
	Negative	FP=10	TN=30

分类 评价指标

项目	符号	猫狗的例子
识别出的正例	TP+FP	40+10=50
识别出的负例	TN+FN	30+20=50
总识别样本数	TP+FP+TN+FN	50+50=100
识别对了的正例与负例	真正例+真负例=TP+TN	40+30=70
识别错了的正例与负例	伪正例+伪负例=FP+FN	10+20=30
实际总正例数量	真正例+伪负例=TP+FN	40+20=60
实际总负例数量	真负例+伪正例=TN+FP	30+10=40

正确率 (Accuracy) $= (TP + TN) / S$
TP + TN = 70, S = 100, 则正确率为:
Accuracy = 70/100 = 0.7

查准率 (Precision) $= TP / (TP + FP)$
TP = 40, TP + FP = 50.
Precision = 40/50 = 0.8

召回率 (Recall) $= TP / (TP + FN)$
TP = 40, TP + FN = 60. 则召回率为:
Recall = 40/60 = 0.67

评价指标详解——正确率

正确率-Accuracy

预测正确的结果占总样本的百分比

$$\text{正确率} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$$

正确率指标的局限性：虽然正确率可以判断总的正确率，但是在样本不平衡的情况下，并不能作为很好的指标来衡量结果。举个简单的例子，比如在一个总样本中，正样本占 90%，负样本占 10%，样本是严重不平衡的。对于这种情况，我们只需要将全部样本预测为正样本即可得到 90% 的高准确率，但实际上我们并没有很用心的分类，只是随便无脑一分而已。这就说明了：**由于样本不平衡的问题，导致了得到的高正确率结果含有很大的水分。即如果样本不平衡，正确率就会失效。**

评价指标详解——查准率

查准率（精确率）--Precision

所有被**预测为正的样本**中实际为正的样本的概率（正例被预测出来的比率），公式如下：

$$\text{查准率} = TP / (TP + FP)$$

查准率和正确率看上去有些类似，但是完全不同的两个概念。查准率代表对正样本结果中的预测准确程度，而正确率则代表整体的预测准确程度，既包括正样本，也包括负样本。

评价指标详解——查全率

查全率（召回率）--Recall

实际为正的样本中被预测为正样本的概率，公式如下：

$$\text{查全率（召回率）} = TP / (TP + FN)$$

召回率的应用场景： 比如拿网贷违约率为例，相对好用户，我们更关心坏用户，不能错放过任何一个坏用户。因为如果我们过多的将坏用户当成好用户，这样后续可能发生的违约金额会远超过好用户偿还的借贷利息金额，造成严重偿失。召回率越高，代表实际坏用户被预测出来的概率越高，它的含义类似：宁可错杀一千，绝不放过一个。

评价指标——举例

某池塘有1400条鲤鱼，300只虾，300只鳖。现在以捕鲤鱼为目的。撒一大网，逮着了700条鲤鱼，200只虾，100只鳖。计算这些指标（查准率、召回率、F值）？

$$\text{查准率} = 700 / (700 + 200 + 100) = 70\%$$

$$\text{召回率} = 700 / 1400 = 50\%$$

$$\text{F值} = 70\% * 50\% * 2 / (70\% + 50\%) = 58.3\%$$

如果把池子里的所有的鲤鱼、虾和鳖都一网打尽，这些指标又有何变化？

$$\text{查准率} : 1400 / (1400 + 300 + 300) = 70\%$$


$$\text{召回率} = 1400 / 1400 = 100\%$$

$$\text{F值} = 70\% * 100\% * 2 / (70\% + 100\%) = 82.35\%$$

正确率是评估捕获的成果中目标成果所占得比例；**召回率**，顾名思义，就是从关注领域中，召回目标类别的比例；当然希望检索结果Precision越高越好，同时Recall也越高越好，但事实上这两者在某些情况下有矛盾的。比如极端情况下，我们只搜索出了一个结果，且是准确的，那么Precision就是100%，但是Recall就很低；而如果我们把所有结果都返回，那么比如Recall是100%，但是Precision就会很低。**因此在不同的场合中需要自己判断希望Precision比较高或是Recall比较高。**

图形化的评价工具—PR曲线

如果我们把查准率（Precision）和召回率（Recall）之间的关系用图来表达，就是下面的P—R曲线：



PR图：

- 学习器 A 优于 学习器 C
- 学习器 B 优于 学习器 C
- 学习器 A ?? 学习器 B

BEP：

- 学习器 A 优于 学习器 B
- 学习器 A 优于 学习器 C
- 学习器 B 优于 学习器 C

查准率和召回率之间是两难全的关系。为了综合两者的表现，在两者之间找一个**平衡点**，就出现了一个F1分数。用于度量P-R曲线有交叉的分类器性能高低。


$$\text{F1 分数} = \frac{2 \times \text{精确率} \times \text{召回率}}{\text{精确率} + \text{召回率}}$$

图形化的评价工具—ROC曲线

- ROC全称是“受试者工作特征”曲线，它源于“二战”中用于敌机检测的雷达信号分析技术，二十世纪六十年代开始被用于一些心理学、医学检测应用中，此后被引入机器学习领域。

由来：

相传是在第二世界大战期间，雷达兵的任务之一就是死盯着雷达显示器，观察是否有敌机来袭，理论上讲，只要有敌机来袭，雷达屏幕上就会出现相应的信号。实际上，如果飞鸟出现在雷达扫描区域时，雷达屏幕上有时候也会出现信号。如果过于谨慎，就会增加误报的风险，如果过于大胆就会出现漏报的风险。为了研究雷达兵预报的准确性，把漏报和误报的概率画到一个二维坐标系里。纵坐标为敏感性（真阳性率），横坐标为特异性（假阳性率）。雷达兵的预报性能进行汇总，发现他们刚好在一条曲线上，即ROC曲线。




$$\text{真正例率TPR} = \text{TP} / (\text{TP} + \text{FN})$$

$$\text{假正例率FPR} = \text{FP} / (\text{TN} + \text{FP})$$

作业1：计算评价指标

混淆矩阵

- 二分类数据集，有两种：正例和负例
- 模型分类之后，也有两种：预测正例和预测负例
- 两种分类方法的交叉，就产生了四种数据集合



计算：

Recall 召回率？

Precision 查准率？

Accuracy 正确率？

作业2：绘制ROC和P-R曲线图

绘图数据来自名为“类别和概率.CSV”的文本文件，其包括两列数据：第1列为模型预测为1类的概率值，第2列为实际标签（0或1）。基本思路：首先，计算实际标签为1和0类的样本量（pos和neg）；之后，将数据按概率值降序重新排列；随后，利用for循环计算绘图所需要的数据FPR、TPR、查全率R和查准率P。