

第5章 支持向量机

浙江理工大学 曹丽

办公室 10-541

支持向量机的内容简介

5.1 硬间隔与支持向量机

5.2 对偶问题

5.3 核函数

5.4 软间隔与正则化


5.5 支持向量回归

5.6 核方法

引子

- 线性判别函数: $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$
- 线性决策面/超平面H: $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = 0$
- 样本集线性可分性 (Linear Separability):
 - 在样本特征空间中, 至少存在一个线性分类面能够把两类样本没有错误地分开, 称样本是线性可分的。
 - $\exists \mathbf{w}, b$, 对 $\forall x_i$, 如果 $x_i \in \omega_1$, 则 $\mathbf{w}^T \mathbf{x} + b > 0$; 如果, $x_i \in \omega_2$, 则 $\mathbf{w}^T \mathbf{x} + b < 0$ 。

Which one is
Linearly Separable?



引子

- 假设特征空间上线性可分的训练样本集：


$$D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\},$$

$$\mathbf{x}_i \in X = \mathbb{R}^d,$$

$$y_i \in Y = \{-1, +1\}, i = 1, 2, \dots, m$$


- 学习目标：找到分类超平面

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = 0$$



引子

□ 超平面选择 → 最优分类超平面(optimal separating hyperplane)



⑩ 一个样本点距离分类超平面的远近可以表示分类预测的**确信程度**。



- 离超平面越远的样本，其被正确分类的确信度较高；
- 离超平面越近的样本，其被正确分类的确信度较低。

引子

- 为了使超平面更具鲁棒性，以最大间隔把两类样本分开的超平面，又称**最大间隔超平面**。
 - 两类样本分别分割在超平面两侧；
 - 两侧距离超平面最近的样本点到超平面的距离被最大化。
- 支持向量机(Support Vector Machine, SVM) 即从线性可分情况下最优分类超平面发展而来。


引子

应选择“**正中间**”，且间隔最大，容忍性好，鲁棒性高，泛化能力最强。




引子

- **间隔(margin):** H_1 、 H_2 分别为过各类中离分类超平面最近的样本且与其平行的直线， H_1 、 H_2 之间的距离为分类间隔。
- **最优分类超平面(optimal separating hyperplane):** 指如果一个超平面能够将训练样本没有错误得分开，且两类训练样本中离超平面最近的样本与超平面之间的距离最大。
- **支持向量(support vector):** 两类样本中离超平面最近的样本，即在 H_1 、 H_2 上的样本。




引子



支持向量的概述

⑩支持向量机（Support Vector Machine, SVM）的基本模型是在特征空间上找到最佳的分离超平面使得训练集上正负样本间隔最大。SVM是用来解决二分类问题的有监督学习算法。

⑩与逻辑回归和神经网络相比，支持向量机，在学习复杂的非线性方程时提供了一种更为清晰，更加强大的方式。




支持向量机概念


支持向量的概述

硬间隔、软间隔和非线性SVM


假如数据是完全线性可分的，那么学习到的模型可以称为硬间隔支持向量机。换个说法，硬间隔指的就是完全分类准确，不能存在分类错误的情况。软间隔，就是容许一定量的样本分类错误。




线性可分



硬间隔



软间隔




线性不可分

支持向量的概述

支持向量的思想

找到集合边缘上的若干数据（称为支持向量），用这些点找出一个平面（称为决策面），使得支持向量到该平面的距离最大。



支持向量机与间隔

间隔与支持向量

背景知识

任意超平面可以用下面这个线性方程来描述：

$$W^T X + b = 0$$


二维空间点 (x, y) 到直线 $Ax + By + C = 0$ 的距离公式是：

$$\frac{|Ax + By + C|}{\sqrt{A^2 + B^2}}$$

扩展到n维空间后，点 $x = (x_1, x_2 \cdots x_n)$ 到超平面

$$W^T X + b = 0 \text{ 的距离为: } \frac{|W^T x + b|}{\|W\|}$$

$$\text{其中 } \|W\| = \sqrt{W_1^2 + \cdots + W_n^2}$$



支持向量机与间隔

如图所示：根据支持向量机的定义，我们知道，支持向量到超平面的距离为 d ，其他点到超平面的距离大于 d 。每个支持向量到超平面的距离可以写为：

$$d = \frac{|W^T x + b|}{\|W\|}$$

间隔与支持向量

给定线性可分的样本集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$,

$\mathbf{x}_i \in X = R^n$, $y_i \in Y = \{-1, +1\}$

超平面H方程为: $\mathbf{w}^T \mathbf{x} + b = 0$

特征空间中任意一个样本点 $\mathbf{x}$ 到超平面H的距离:

$$r = \frac{|\mathbf{w}^T \mathbf{x} + b|}{\|\mathbf{w}\|}$$

间隔与支持向量

若所有训练样本都被超平面H正确分类，需要满足

$$\begin{cases} \mathbf{w}^T \mathbf{x}_i + b > 0, y_i = +1 \\ \mathbf{w}^T \mathbf{x}_i + b < 0, y_i = -1 \end{cases}$$

若所有训练样本（包括支持向量）都以较高确信度和正确性，则

$$\begin{cases} \frac{\mathbf{w}^T \mathbf{x}_i + b}{\|\mathbf{w}\|} \geq d, y_i = +1 \\ \frac{\mathbf{w}^T \mathbf{x}_i + b}{\|\mathbf{w}\|} \leq -d, y_i = -1 \end{cases}$$


$$\Rightarrow \begin{cases} \frac{\mathbf{w}^T \mathbf{x}_i + b}{\|\mathbf{w}\|d} \geq 1, y_i = +1 \\ \frac{\mathbf{w}^T \mathbf{x}_i + b}{\|\mathbf{w}\|d} \leq -1, y_i = -1 \end{cases}$$

$$\|\mathbf{w}\|d=1$$

规范化

$$\begin{cases} \mathbf{w}^T \mathbf{x}_i + b \geq 1, y_i = +1 \\ \mathbf{w}^T \mathbf{x}_i + b \leq -1, y_i = -1 \end{cases}$$

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \\ \text{则有 } |\mathbf{w}^T \mathbf{x}_i + b| = y_i(\mathbf{w}^T \mathbf{x}_i + b)$$



间隔与支持向量

间隔：两个异类支持向量到超平面的距离之和

$$\gamma = 2d = \frac{2}{\|\mathbf{w}\|}$$

最大间隔(maximum margin)：寻找参数 $\mathbf{w}$ 和 b ，使得 γ 最大


$$\begin{aligned} \max_{\mathbf{w}, b} \quad & \frac{2}{\|\mathbf{w}\|} \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, m \end{aligned}$$



$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, m \end{aligned}$$

求解约束最优化问题得到最优解 $\mathbf{w}^*$ 和 b^* ，得到：

- 超平面 $\mathbf{w}^{*T} \mathbf{x} + b^* = 0$ ，
- 分类决策函数 $f(\mathbf{x}) = \text{sign}(\mathbf{w}^{*T} \mathbf{x} + b^*)$



SVM原始问题：需要求解 $n + 1$ 个变量($\mathbf{w}$, b)，不等式约束条件有 m 个，适用于数据维度较小的情况。

5.2 对偶问题

SVM原始问题:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$
$$s. t. y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, m$$

拉格朗日函数: 为每条不等式约束添加拉格朗日乘子 $\alpha_i \geq 0$, 得到拉格朗日函数, 其中 $\boldsymbol{\alpha} = (\alpha_1, \alpha_2, \dots, \alpha_m)^T$:

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i(\mathbf{w}^T \mathbf{x}_i + b))$$

SVM原始问题→SVM对偶问题 (极大极小问题)

$$\max_{\boldsymbol{\alpha}} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha})$$

为了得到对偶问题的解, 需要先求 $L(\mathbf{w}, b, \boldsymbol{\alpha})$ 对 $\mathbf{w}, b$ 的极小 $\min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha})$, 再求对 $\boldsymbol{\alpha}$ 的极大 $\max_{\boldsymbol{\alpha}} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha})$

5.2 对偶问题

$$\begin{aligned} L(\mathbf{w}, b, \alpha) &= \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i (\mathbf{w}^T \mathbf{x}_i + b)) \\ &= \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \alpha_i y_i \mathbf{w}^T \mathbf{x}_i - \sum_{i=1}^m \alpha_i y_i b \end{aligned}$$

(1) 求 $\min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha)$, 令 $L(\mathbf{w}, b, \alpha)$ 对 $\mathbf{w}$ 和 b 的偏导为零

$$\frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i = 0, \text{ 得 } \mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial L}{\partial b} = -\sum_{i=1}^m \alpha_i y_i = 0, \text{ 得 } \sum_{i=1}^m \alpha_i y_i = 0$$

将以上求解结果代入 $L(\mathbf{w}, b, \alpha)$, 得到

$$\max_{\alpha} L(\mathbf{w}, b, \alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

$$\min_{\alpha} L(\mathbf{w}, b, \alpha) = -\sum_{i=1}^m \alpha_i + \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

5.2 对偶问题

(2) 求 $\min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha})$ 对 $\boldsymbol{\alpha}$ 的极大, 即

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha}) &= \max_{\boldsymbol{\alpha}} \left(\sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right) \\ \text{s. t. } \sum_{i=1}^m \alpha_i y_i &= 0, \alpha_i \geq 0, i = 1, 2, \dots, m \end{aligned}$$

求得 α_i 后回代, 求得 $\mathbf{w}$ 和 b , $\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i$ $b = y_j - \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_j$

得 $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b$


综上所述, 对于给定的线性可分训练数据集, 可以首先求对偶问题的解 α_i ; 再利用公式求得原始问题的解 $\mathbf{w}$ 和 b ; 从而得到分类超平面及分类决策函数。这种算法称为线性可分支持向量机的对偶学习算法, 是线性可分支持向量机学习的算法。

5.2 对偶问题

最终模型: $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b$

SVM满足KKT(Karush-Kuhn-Tucker)条件:

$$\begin{cases} \alpha_i \geq 0 \\ y_i f(\mathbf{x}_i) \geq 1 \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0 \end{cases}$$



对任意训练样本 $(\mathbf{x}_i, y_i)$, 必有 $\alpha_i = 0$ 或 $y_i f(\mathbf{x}_i) = 1$


- 若 $\alpha_i = 0$, 则 $y_i f(\mathbf{x}_i) > 1$, 样本不会对模型 $f(\mathbf{x})$ 有任何影响;
- 若 $\alpha_i > 0$, 则 $y_i f(\mathbf{x}_i) = 1$, 对应样本位于边界超平面上, 即支持向量。

支持向量机解的**稀疏性**: 训练完成后, 大部分的训练样本都不需保留, 最终模型仅与支持向量有关。

对偶问题只需找出支持向量和其对应的 α

例题1—SVM对偶问题求解

例题1：已知训练数据集，其中正例为 $x_1 = (3; 3)$, $y_1 = +1$, $x_2 = (4; 3)$, $y_2 = +1$ ；反例为 $x_3 = (1; 1)$, $y_3 = -1$ 。试求最大间隔分离超平面。



求解 $w = (w_1; w_2)$ 和 b

例题1—SVM对偶问题求解

SVM原始问题

$$\min_{\mathbf{w}, b} \frac{1}{2} (w_1^2 + w_2^2)$$
$$s. t. \begin{cases} 3w_1 + 3w_2 + b \geq 1 \\ 4w_1 + 3w_2 + b \geq 1 \\ -w_1 - w_2 + b \geq 1 \end{cases}$$

第一步：转化为SVM对偶问题

$$\max_{\alpha_1, \alpha_2, \alpha_3} \left(\sum_{i=1}^3 \alpha_i - \frac{1}{2} \sum_{i=1}^3 \sum_{j=1}^3 \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right)$$
$$s. t. \begin{cases} \alpha_1 + \alpha_2 - \alpha_3 = 0 \\ \alpha_1 \geq 0, \alpha_2 \geq 0, \alpha_3 \geq 0 \end{cases}$$



$$\min_{\alpha_1, \alpha_2, \alpha_3} \left(\frac{1}{2} (18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 42\alpha_1\alpha_2 - 12\alpha_1\alpha_3 - 14\alpha_2\alpha_3) - \alpha_1 - \alpha_2 - \alpha_3 \right)$$
$$s. t. \begin{cases} \alpha_1 + \alpha_2 - \alpha_3 = 0 \\ \alpha_1 \geq 0, \alpha_2 \geq 0, \alpha_3 \geq 0 \end{cases}$$

$$\max_{\alpha} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha)$$
$$= \max_{\alpha} \left(\sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right)$$
$$s. t. \sum_{i=1}^m \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, 2, \dots, m$$

例题1—SVM对偶问题求解

第二步：代入约束条件 $\alpha_3 = \alpha_1 + \alpha_2$ ，目标函数变形为：

$$s(\alpha_1, \alpha_2) = 4\alpha_1^2 + \frac{13}{2}\alpha_2^2 + 10\alpha_1\alpha_2 - 2\alpha_1 - 2\alpha_2$$
$$s.t. \alpha_1 \geq 0, \alpha_2 \geq 0, \alpha_3 \geq 0$$

目标函数对 α_1, α_2 求偏导，并令偏导数为0：

$$\begin{cases} \frac{\partial s}{\partial \alpha_1} = 8\alpha_1 + 10\alpha_2 - 2 = 0 \\ \frac{\partial s}{\partial \alpha_2} = 13\alpha_2 + 10\alpha_1 - 2 = 0 \end{cases}$$

$$\text{求得} \begin{cases} \alpha_1 = \frac{3}{2} \\ \alpha_2 = -1 < 0, \\ \alpha_3 = \frac{1}{2} \end{cases}$$

不符合约束条件！因此最小值应在边界上达到。

例题1—SVM对偶问题求解

第三步：利用KKT条件，计算向量 $\mathbf{w}$

(1) 当 $\alpha_1 = 0$ 时，

$$s(0, \alpha_2) = \frac{13}{2} \alpha_2^2 - 2\alpha_2,$$

则令 $\frac{\partial s}{\partial \alpha_2} = 13\alpha_2 - 2 = 0$ ，得 $\alpha_2 = \frac{2}{13}$ ， $s_{min} = -\frac{2}{13}$

(2) 当 $\alpha_2 = 0$ 时，

$$s(\alpha_1, 0) = 4\alpha_1^2 - 2\alpha_1,$$

则令 $\frac{\partial s}{\partial \alpha_1} = 8\alpha_1 - 2 = 0$ ，得 $\alpha_1 = \frac{1}{4}$ ， $s_{min} = -\frac{1}{4}$

从而，当 $\alpha_1 = \frac{1}{4}$ ， $\alpha_2 = 0$ ， $\alpha_3 = \frac{1}{4}$ 时， $s_{min} = -\frac{1}{4}$

因此， $\mathbf{w} = \sum_{i=1}^3 \alpha_i y_i \mathbf{x}_i = \alpha_1 y_1 \mathbf{x}_1 + \alpha_3 y_3 \mathbf{x}_3 = (\frac{1}{2}, \frac{1}{2})$

例题1—SVM对偶问题求解

第四步：利用KKT条件，计算 b

由第三步求解结果， $\alpha_1 = \frac{1}{4} > 0$ ，从而对应样本 $\mathbf{x}_1$ 为支持向量，有 $y_1 f(\mathbf{x}_1) = 1$ ，则 $b = -2$ 。

由此，得到支持向量机（分类超平面）


$$\frac{1}{2}x_1 + \frac{1}{2}x_2 - 2 = 0$$

对于新样本，分类决策函数为

$$f(\mathbf{x}) = \text{sign}\left(\frac{1}{2}x_1 + \frac{1}{2}x_2 - 2\right)$$

SVM对偶问题正比于训练样本数目，如果样本变多，人工计算不现实，需要一种高效的计算算法。

5.3 核函数



香蕉和苹果不能用直线分割怎么办呢？

5.3 核函数


Q: 若训练样本集是线性不可分的，不存在一个分类超平面能将训练样本正确分类。即约束条件 $y_i(w^T x_i + b) \geq 1$ 不能被所有样本同时满足。如何确定最大间隔超平面？

A: 将样本从原始低维空间映射到一个更高维的特征空间，使得样本在这个特征空间内线性可分，即可在高维空间计算最大间隔超平面。



低维映射到高维 $x \mapsto \phi(x)$

5.3 核函数



核技巧的关键在于空间映射，即将低维数据映射到高维空间中，使得数据集在高维空间能被线性可分。





5.3 核函数



$$\phi(x) = x^2$$



$$\phi(x) = x \bmod 2$$



$$\phi(x) = \begin{pmatrix} x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \end{pmatrix}$$

5.3 核函数

设样本 $\mathbf{x}$ 映射后的向量为 $\phi(\mathbf{x})$ ，分类超平面为 $f(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b = 0$

映射后SVM原始问题：

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i (\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1, i = 1, 2, \dots, m \end{aligned}$$

映射后SVM对偶问题： $\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \phi(\mathbf{x}_i)$

$$\begin{aligned} \max_{\alpha} \quad & \left(\sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) \right) \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, 2, \dots, m \end{aligned}$$

样本映射到高
维特征空间后
的内积，标量

求解后预测：

$$f(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) + b$$

5.3 核函数


线性可分情况下:最优超平面的决策函数:

$$f(\mathbf{x}) = \text{sign}(\mathbf{w}^T \mathbf{x} + b) = \text{sign}\left(\sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b\right)$$

线性不可分情况下: 设样本 $\mathbf{x}$ 映射后的向量为 $\phi(\mathbf{x})$, 则分类超平面的决策函数:

$$f(\mathbf{x}) = \text{sign}(\mathbf{w}^T \phi(\mathbf{x}) + b) = \text{sign}\left(\sum_{i=1}^m \alpha_i y_i \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) + b\right)$$

用核函数来替换原来的内积。



即通过一个非线性转换后的两个样本间的内积。具体地, $K(x, z)$ 是一个核函数, 或正定核, 意味着存在一个从输入空间到特征空间的映射, 对于任意空间输入的 x, z 有:

$$K(x, z) = \phi(x) \cdot \phi(z)$$

5.3 核函数

基本想法：不显式地设计核映射 $\phi(\mathbf{x})$ ，而是设计核函数(kernel function)

$$k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

映射后SVM对偶问题可重写为：

$$\begin{aligned} \max_{\alpha} & \left(\sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j k(\mathbf{x}_i, \mathbf{x}_j) \right) \\ \text{s. t. } & \sum_{i=1}^m \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, 2, \dots, m \end{aligned}$$

决策函数可重写为：

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^m \alpha_i y_i k(\mathbf{x}_i, \mathbf{x}) + b \right)$$

5.3 核函数

基本想法：不显式地设计核映射 $\phi(\mathbf{x})$ ，而是设计核函数(kernel function)

$$k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

Mercer定理（充分非必要）：只要一个对称函数所对应的核矩阵(kernel matrix)是半正定的，则该对称函数就能作为核函数来使用。

$$\text{核矩阵 } \mathbf{K} = \begin{bmatrix} \kappa(\mathbf{x}_1, \mathbf{x}_1) & \kappa(\mathbf{x}_1, \mathbf{x}_2) & \kappa(\mathbf{x}_1, \mathbf{x}_3) & \cdots & \kappa(\mathbf{x}_1, \mathbf{x}_m) \\ \kappa(\mathbf{x}_2, \mathbf{x}_1) & \kappa(\mathbf{x}_2, \mathbf{x}_2) & \kappa(\mathbf{x}_2, \mathbf{x}_3) & \cdots & \kappa(\mathbf{x}_2, \mathbf{x}_m) \\ \kappa(\mathbf{x}_3, \mathbf{x}_1) & \kappa(\mathbf{x}_3, \mathbf{x}_2) & \kappa(\mathbf{x}_3, \mathbf{x}_3) & \cdots & \kappa(\mathbf{x}_3, \mathbf{x}_m) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \kappa(\mathbf{x}_m, \mathbf{x}_1) & \kappa(\mathbf{x}_m, \mathbf{x}_2) & \kappa(\mathbf{x}_m, \mathbf{x}_3) & \cdots & \kappa(\mathbf{x}_m, \mathbf{x}_m) \end{bmatrix}$$

对于一个半正定核矩阵，总能找到一个与之对应的映射 ϕ 。因此，任何一个核函数都隐式地定义了一个称为“再生核希尔伯特空间”(Reproducing Kernel Hilbert Space, RKHS)的特征空间。

5.3 核函数

基本想法：不显式地设计核映射 $\phi(\mathbf{x})$ ，而是设计核函数(kernel function)

$$k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

Mercer定理（充分非必要）：只要一个对称函数所对应的核矩阵(kernel matrix)是半正定的，则该对称函数就能作为核函数来使用。

常用核函数：

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\delta^2}\right)$	$\delta > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$	$\tanh$ 为双曲正切函数, $\beta > 0, \theta < 0$

5.3 核函数

核函数注意事项:

核函数选择为SVM的最大变数。

经验: 文本数据使用线性核, 情况不明使用高斯核。

核函数的性质:

1. 核函数 k_1, k_2 的线性组合 $\gamma_1 k_1 + \gamma_2 k_2$ 仍为核函数
2. 核函数 k_1, k_2 的直积仍为核函数

$$k_1 \otimes k_2(\mathbf{x}_1, \mathbf{x}_2) = k_1(\mathbf{x}_1, \mathbf{x}_2)k_2(\mathbf{x}_1, \mathbf{x}_2)$$


3. 若 $k_1(\mathbf{x}_1, \mathbf{x}_2)$ 为核函数, 则对于任意函数 $g(\mathbf{x})$,

$$k(\mathbf{x}_1, \mathbf{x}_2) = g(\mathbf{x}_1)k_1(\mathbf{x}_1, \mathbf{x}_2)g(\mathbf{x}_2) \text{ 仍为核函数。}$$


5.3 核函数

例子：

假设现在你是一个农场主，圈养了一批牛群，但为预防狼群袭击牛群，你需要搭建一个篱笆来把牛群围起来。但是篱笆应该建在哪里呢？



5.4 软间隔与正则化



香蕉和苹果有交集怎么办呢？

5.4 软间隔与正则化


硬间隔(hard margin)支持向量机对所有训练样本是线性可分的，满足：

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$


Q：现实中，很难确定合适的核函数使得训练样本在特征空间中线性可分；同时一个线性可分的结果也很难断定是否是有过拟合造成的。

A：引入“软间隔”(soft margin)的概念，允许SVM在一些样本上不满足以上约束条件，即允许一些样本即使落入间隔内。

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$



硬间隔SVM



软间隔SVM

5.4 软间隔与正则化

基本想法：最大化间隔的同时，让不满足约束的样本尽可能少。

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m l_{0/1}(y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1)$$

其中 $l_{0/1}$ 为“0/1损失函数”

$$l_{0/1}(z) = \begin{cases} 1, & z < 0 \\ 0, & \text{otherwise} \end{cases}$$

正则化常数 $C > 0$ ，如果 C 为无穷大，则等价于要求所有样本点都分类正确，否则只允许一部分极少的样本分类错误。


0/1损失函数非凸、非连续，不易优化！

可使用“替代损失” (surrogate loss) 函数来代替 $l_{0/1}$

5.4 软间隔与正则化

替代损失函数

软间隔SVM



替代损失函数数学性质较好, 一般是0/1损失函数的上界

5.4 软间隔与正则化

采用hinge损失，则软间隔SVM原始问题：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b))$$

为每一个样本引入“松弛变量” (slack variables) $\xi_i \geq 0$ ，用于表征该样本不满足约束 $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ 的程度。

软间隔SVM原始问题变为：

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, i = 1, 2, \dots, m \end{aligned}$$

5.4 软间隔与正则化

软间隔SVM原始问题:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$
$$s. t. y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$
$$\xi_i \geq 0, i = 1, 2, \dots, m$$

构造拉格朗日函数: 为每个不等式约束添加拉格朗日乘子 $\alpha_i \geq 0$, $\mu_i \geq 0$, 得到拉格朗日函数

$$L(\mathbf{w}, b, \alpha, \xi, \mu) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i (1 - \xi_i - y_i(\mathbf{w}^T \mathbf{x}_i + b)) - \sum_{i=1}^m \mu_i \xi_i$$
$$s. t. \alpha_i \geq 0, \mu_i \geq 0$$

软间隔SVM原始问题 → 软间隔SVM对偶问题 (极大极小问题)

$$\max_{\alpha, \mu} \min_{\mathbf{w}, b, \xi} L(\mathbf{w}, b, \alpha, \xi, \mu)$$

为了得到对偶问题的解, 先求 $L(\mathbf{w}, b, \alpha, \xi, \mu)$ 对 $\mathbf{w}, b, \xi$ 的极小 $\min_{\mathbf{w}, b, \xi} L(\mathbf{w}, b, \alpha, \xi, \mu)$, 再

求对 α, μ 的极大 $\max_{\alpha, \mu} \min_{\mathbf{w}, b, \xi} L(\mathbf{w}, b, \alpha, \xi, \mu)$

5.4 软间隔与正则化

$$\begin{aligned} L(\mathbf{w}, b, \alpha, \xi, \mu) &= \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i (1 - \xi_i - y_i(\mathbf{w}^T \mathbf{x}_i + b)) - \sum_{i=1}^m \mu_i \xi_i \\ &= \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \alpha_i \xi_i - \sum_{i=1}^m \alpha_i y_i \mathbf{w}^T \mathbf{x}_i - \sum_{i=1}^m \alpha_i y_i b - \sum_{i=1}^m \mu_i \xi_i \end{aligned}$$

(1) 求 $\min_{\mathbf{w}, b, \xi} L(\mathbf{w}, b, \alpha, \xi, \mu)$, 令 $L(\mathbf{w}, b, \alpha, \xi, \mu)$ 对 $\mathbf{w}, b, \xi$ 的偏导为 0

$$\frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i = 0, \text{ 得 } \mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial L}{\partial b} = -\sum_{i=1}^m \alpha_i y_i = 0, \text{ 得 } \sum_{i=1}^m \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \xi} = C - \alpha_i - \mu_i = 0, \text{ 得 } C = \alpha_i + \mu_i$$

将以上所求代入 $L(\mathbf{w}, b, \alpha, \xi, \mu)$, 得到

$$\min_{\mathbf{w}, b, \xi} L(\mathbf{w}, b, \alpha, \xi, \mu) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

5.4 软间隔与正则化

(2) 求 $\min_{\mathbf{w}, b, \xi} L(\mathbf{w}, b, \alpha, \xi, \mu)$ 对 α, μ 的极大, 即

$$\max_{\alpha, \mu} \min_{\mathbf{w}, b, \xi} L(\mathbf{w}, b, \alpha, \xi, \mu) = \max_{\alpha, \mu} \left(\sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \right)$$

$$s.t. \sum_{i=1}^m \alpha_i y_i = 0, 0 \leq \alpha_i \leq C, i = 1, 2, \dots, m$$

求得 α_i 和 μ_i 后回代, 求得 $\mathbf{w}, b$,

得到 $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b$

5.4 软间隔与正则化

最终软间隔SVM模型: $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b$

软间隔SVM满足KKT条件:

$$\begin{cases} \alpha_i \geq 0, \mu_i \geq 0 \\ y_i f(\mathbf{x}_i) - 1 + \xi_i \geq 0 \\ \alpha_i (y_i f(\mathbf{x}_i) - 1 + \xi_i) = 0 \\ \xi_i \geq 0, \mu_i \xi_i = 0 \end{cases} \quad \Rightarrow \quad \begin{aligned} &\text{对任意训练样本}(\mathbf{x}_i, y_i), \text{必有} \alpha_i = 0 \\ &\text{或 } y_i f(\mathbf{x}_i) = 1 - \xi_i \end{aligned}$$

- 若 $\alpha_i = 0$, 则 $y_i f(\mathbf{x}_i) > 1 - \xi_i$, 样本不会对模型 $f(\mathbf{x})$ 有任何影响;
- 若 $\alpha_i > 0$, 则 $y_i f(\mathbf{x}_i) = 1 - \xi_i$, 即该样本是支持向量;
- 由 $C = \alpha_i + \mu_i > 0$ 可知, 若 $\alpha_i < C$, 则 $\mu_i > 0$, 进而有 $\xi_i = 0$, 即该样本恰好在最大间隔边界上;
- 若 $\alpha_i = C$, 则 $\mu_i = 0$, 此时若 $\xi_i \leq 1$, 则样本落在最大间隔内部; 若 $\xi_i > 1$, 则样本被错误分类。

根据KKT条件可推得最终模型仅与支持向量有关, 也即hinge损失函数依然保持了支持向量机解的稀疏性。

5.4 软间隔与正则化

正则化

支持向量机器学习模型的更一般形式，正则化(regularization)问题

$$\min_f \Omega(f) + C \sum_{i=1}^m l(f(\mathbf{x}_i), y_i)$$

$\Omega(f)$: 正则化项。又称“结构风险”，描述模型 f 的某些性质，即所求解的目标函数； $L_p = (\sum |\mathbf{x}_i|^p)^{\frac{1}{p}}$ 范数是常用的正则化项，其中 L_2 表示权值向量 $\mathbf{w}$ 中各元素平方和再求平方根，倾向于各分量取值尽量平衡，防止过拟合； L_1 表示 $\mathbf{w}$ 中各元素的绝对值之和， L_0 表示非0元素的个数， L_1 和 L_0 倾向于 $\mathbf{w}$ 的分量尽量稀疏，非0个数尽量少。

$\sum_{i=1}^m l(f(\mathbf{x}_i), y_i)$: 损失函数。又称“经验风险”，描述模型与训练数据的契合程度。

C : 正则化常数。用于对二者进行中和。

总结

支持向量机（SVM）是一种高效快速的机器学习算法，在解决小样本即非线性及高维模式识别中表示出许多特有的优势。本章从最简单的二分类线性可分问题开始，介绍了SVM的基本思想：找到一个线性分类的最优超平面，使得分类间隔最大，即最大化最接近分类超平面的样本到超平面的距离。线性可分支持向量机存在最优解且唯一，位于间隔边界上样本点即是支持向量。

对于非线性数据，可以通过核函数将原始数据映射为高维特征空间中，再在高维空间中训练线性支持向量机。常用的核函数包括多项式核函数、高斯核函数和Sigmoid核函数。

SVM的最终决策函数只有由少数的支持向量所确定，计算的复杂性取决于支持向量的数目，而不是样本空间的维数，这在某种意义上避免了“维数灾难”。另外，分类结果只依赖于少部分支持向量也使得算法具有较好的鲁棒性。

总结—线性可分支持向量机、线性支持向量机、线性不可分支持向量机的区别

线性可分支持向量机：针对于线性可分的数据集；

线性支持向量机：针对不能够严格线性可分的数据集；

线性不可分支持向量机：针对线性不可分的数据集，将样本从原始空间映射到一个更高维的特质空间，使得样本在新的空间中线性可分。

下面是一些SVM普遍使用的准则：


n 为特征数， m 为训练样本数。

- (1) 如果相较于 m 而言， n 要大许多，即训练集数据量不够支持我们训练一个复杂的非线性模型，我们选用逻辑回归模型或者不带核函数的支持向量机。
- (2) 如果 n 较小，而且 m 大小中等，例如 n 在1-1000之间，而 m 在10-10000之间，使用高斯核函数的支持向量机。
- (3) 如果 n 较小，而 m 较大，例如 n 在1-1000之间，而 m 大于50000，则使用支持向量机会非常慢，解决方案是创造、增加更多的特征，然后使用逻辑回归或者不带核函数的支持向量机。

案例：支持向量机案例：Python实现支持向量机分类图片

数据集： Digits 数据集主要由 8×8 大小的阿拉伯数字图片构成，数据集包含了1797个样本，分为0~9 十种不同的数字，数据集的样本图片如下所示：

要求： 在分类的过程中，首先读取数据集，并将其随机分割成80%的训练集和20%的测试集，然后再训练集上采用高斯函数的SVM分类器，并在验证集上测试准确率，最后输出混淆矩阵和分类报告。



Digits 数据集数字图片

案例：支持向量机案例：Python实现支持向量机分类图片

识别结果：

测试集准确率和分类报告。

```
print('The Accuracy of Linear SVC is', lsvc.score(X_test, Y_test))
```

The Accuracy of Linear SVC is 0.9488888888888889

```
from sklearn.metrics import classification_report  
print(classification_report(Y_test, Y_predict, target_names=digits.target_names.astype(str)))
```

	precision	recall	f1-score	support
0	0.92	1.00	0.96	35
1	0.95	0.98	0.96	54
2	0.98	1.00	0.99	44
3	0.93	0.93	0.93	46
4	0.97	1.00	0.99	35
5	0.94	0.94	0.94	48
6	0.96	0.98	0.97	51
7	0.92	1.00	0.96	35
8	0.98	0.83	0.90	58
9	0.95	0.91	0.93	44
accuracy			0.95	450
macro avg	0.95	0.96	0.95	450
weighted avg	0.95	0.95	0.95	450

SVC支持向量机识别准确率结果截图