


第6章 决策树

Decision Tree Modeling

决策树是一种简单且应用广泛的预测方法


动画讲

决策树
(decision tree)



树形数据结构

+




信息熵



决策树的应用

早期人工
智能算法



决策树




医学诊断




商业决策

决策实例



决策实例

下图给出了一个**商业上使用的决策树**的例子。它表示了一个**关心电子产品的用户是否会购买PC** (buys_computer) 的知识，用它**可以预测某条记录（某个人）的购买意向**。



- 这棵决策树对销售记录进行分类，指出一个电子产品消费者是否会购买一台计算机“buys_computer”。每个内部结点(方形框)代表对某个属性的一次检测。每个叶结点(椭圆框)代表一个类：

buys_computers=yes 或者 buys_computers=no

- 在这个例子中，特征向量为：

(age, student, credit_rating, buys_computers)

- 被决策数据的格式为：


(age, student, credit_rating)

- 输入新的被决策的记录，可以预测该记录隶属于哪个类。

使用决策树进行分类

- 第1步：利用训练集建立并精化一棵决策树，建立决策树模型。这个过程实际上是一个从数据中获取知识，进行机器学习的过程。
- 第2步：利用生成完毕的决策树对输入数据进行分类。对输入的记录，从根结点依次测试记录的属性值，直到到达某个叶结点，从而找到该记录所在的类。

如何从训练数据中学习决策树？



决策树学习的关键是 选择最优划分属性

什么样的划分属性是最优的？

我们希望决策树的分支结点所包含的样本尽可能属于同一类别，即结点的“纯度”越来越高，可以高效地从根结点到达叶结点，得到决策结果。

三种度量结点“纯度”的指标：

1. 信息增益
2. 增益率
3. 基尼指数

信息熵 (Entropy)

- 我们常说信息很多，或信息很少，但却很难说清楚信息到底有多少。
- 这个问题几千年来都没有人给出很好的解答，直到1948年，香农 (Claude Shannon) 在他著名的论文“通信的数学原理”中提出了**信息熵**的概念，才解决了**信息的度量问题**，并且**量化出信息的作用**。

信息熵(Entropy)

- 一条信息的信息量和它的不确定性有着直接的关系
- 比如，要搞清楚一件非常不确定的事，或是我们一无所知的事情，就需要了解大量信息。相反，如果我们对某件事已经有了较多了解，那么不需要太多信息就能把它搞清楚
- 从这个角度看，信息量就等于不确定性的多少
如何量化信息的度量呢？

信息熵 (Entropy)

- 假如我错过了一个有32支球队参加的足球赛，赛后我问一个知道比赛结果的观众“哪支球队是冠军”？他不愿意直接告诉我，而让我猜，每猜一次，他要收一元钱才肯告诉我是否猜对，那我需要付多少钱才能知道谁是冠军呢？
- ☁ 我可以把球队编号，从1到32，然后问“冠军球队在1-16号中吗？”，假如他告诉我猜对了，我就接着问“冠军在1-8号中吗？”，假如他说猜错了，那我就知道冠军在9-16号中。这样只要5次，我就能知道哪支球队是冠军
- ☁ 当然，香农不是用钱，而是用比特(bit)来度量信息量，在上例中，这条消息的信息量是5比特

信息量的比特数和所有可能情况的对数有关，例如本例中， $\text{信息量} = \log(\text{球队数})$ ，
即 $5 = \log(32)$

信息熵 (Entropy)

- 实际上可能不需要5次就能猜出谁是冠军，因为一些强队得冠的可能性更高，因此第一次猜测时可以把少数几支强队分成一组，其它球队分成另一组，然后猜冠军球队是否在那几支强队中，
- 这样，也许三次或四次就能猜出结果。因此，当每支球队夺冠的可能性(概率)不等时，这条信息的信息量比5比特少，
- 香农指出，它的准确信息量应该是

$$H = -(p_1 \cdot \log p_1 + p_2 \cdot \log p_2 + \dots + p_{32} \cdot \log p_{32})$$

$p_1, p_2, \dots, p_{32}$ 分别是这32支球队夺冠概率，香农把它称作**信息熵，单位为比特**；
可以算出，当32支球队夺冠概率相同时，对应的信息熵为5比特。

信息熵 (Entropy)

对于任意一个随机变量 X (比如夺冠球队)，它的熵定义为

$$H(X) = - \sum_{x \in X} P(x) \log P(x)$$

变量的不确定性越大，熵也就越大，把它搞清楚所需要的信息量也就越大

使用熵衡量数据纯度

假设有一个数据集D，其中只有两个类，一个是正例类，一个是负例类
计算D中正例类和负例类在三种不同的组分下熵的变化情况。

(1) D中包含有50%的正例和50%的负例。

$$H(D) = -0.5 * \log_2 0.5 - 0.5 * \log_2 0.5 = 1$$

(2) D中包含有20%的正例和80%的负例。

$$H(D) = -0.2 * \log_2 0.2 - 0.8 * \log_2 0.8 = 0.722$$

(3) D中包含有100%的正例和0%的负例。

$$H(D) = -1 * \log_2 1 - 0 * \log_2 0 = 0$$

可以看到一个趋势，当数据变得越来越“纯”时，熵的值变得越来越小。

当D中正反例所占比例相同时，熵取最大值。

当D中所有数据都只属于一个类时，熵得到最小值。

因此熵可以作为数据纯净度或混乱度的衡量指标。这正是决策树学习中需要的。

数据集的信息熵

设数据集D中有m个不同的类 $C_1, C_2, C_3, \dots, C_m$

设 $C_{i,D}$ 是数据集D中 C_i 类的样本的集合, $|D|$ 和 $|C_{i,D}|$ 分别是D和 $C_{i,D}$ 中的样本个数

数据集D的信息熵:

$$Info(D) = - \sum_{i=1}^m p_i \log_2 p_i$$

其中 p_i 是数据集D中任意样本属于类 C_i 的概率, 用 $\frac{|C_{i,D}|}{|D|}$ 估计

例: 计算对下列数据集分类所需的信息熵

年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中等	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否

$$|D|=14$$

$$|C_{1,D}|=5$$

$$|C_{2,D}|=9$$

$$Info(D)$$

$$= -\frac{5}{14} \log_2 \frac{5}{14} - \frac{9}{14} \log_2 \frac{9}{14}$$
$$= 0.940$$

数据集的信息熵

假设按属性 A 划分 D 中的样本，且属性 A 根据训练数据的观测具有 v 个不同取值 $\{a_1, a_2, \dots, a_j, \dots, a_v\}$ 。

如果 A 是离散值，可依属性 A 将 D 划分为 v 个子集 $\{D_1, D_2, \dots, D_j, \dots, D_v\}$

其中， D_j 为 D 中的样本子集，它们在 A 上具有属性值 a_j

这些划分将对应于从该节点 A 出来的分支。

按属性 A 对 D 划分后，数据集的信息熵：

$$Info_A(D) = \sum_{j=1}^v \left[\left(\frac{|D_j|}{|D|} \right) * Info(D_j) \right]$$


其中， $\frac{|D_j|}{|D|}$ 充当第 j 个划分的权重。

$Info_A(D)$ 越小，
表示划分的纯度越高

信息增益


$$Gain(A) = Info(D) - Info_A(D)$$

选择具有最高信息增益 $Gain(A)$
的属性 A 作为分裂属性



按照能做“最佳分类”的属性 A 划分，
使完成样本分类需要的信息量最小

$$\max Gain(A)$$



$$\min Info_A(D)$$

确定第一次分裂的属性：按年龄划分

年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中等	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否

年龄<30的有5个, 其中3个为“否”

年龄30-40的有4个, 其中0个为“否”

年龄>40的有5个, 其中2个为“否”

$\text{Info}_{\text{年龄}}(D)$

$$\begin{aligned} &= \frac{5}{14} \left(-\frac{3}{5} \log \frac{3}{5} - \frac{2}{5} \log \frac{2}{5} \right) \\ &+ \frac{4}{14} \left(-\frac{4}{4} \log \frac{4}{4} - \frac{0}{4} \log \frac{0}{4} \right) \\ &+ \frac{5}{14} \left(-\frac{2}{5} \log \frac{2}{5} - \frac{3}{5} \log \frac{3}{5} \right) \\ &= 0.694 \end{aligned}$$

$\text{Gain}(\text{年龄})$

$$\begin{aligned} &= \text{Info}(D) - \text{Info}_{\text{年龄}}(D) \\ &= 0.940 - 0.694 = 0.246 \end{aligned}$$

确定第一次分裂的属性：按收入划分

年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否

收入=高的有4个, 其中2个为“否”

收入=中的有6个, 其中2个为“否”

收入=低的有4个, 其中1个为“否”

$\text{Info}_{\text{收入}}(D)$

$$\begin{aligned} &= \frac{4}{14} \left(-\frac{2}{4} \log \frac{2}{4} - \frac{2}{4} \log \frac{2}{4} \right) \\ &+ \frac{6}{14} \left(-\frac{2}{6} \log \frac{2}{6} - \frac{4}{6} \log \frac{4}{6} \right) \\ &+ \frac{4}{14} \left(-\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4} \right) \\ &= 0.911 \end{aligned}$$

$\text{Gain}(\text{收入})$

$= \text{Info}(D) - \text{Info}_{\text{收入}}(D)$

$= 0.940 - 0.911 = 0.029$

确定第一次分裂的属性：按学生划分

年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否

是学生的有7个, 其中1个为“否”

不是学生的有7个, 其中4个为“否”

$\text{Info}_{\text{学生}}(D)$

$$\begin{aligned} &= \frac{7}{14} \left(-\frac{1}{7} \log \frac{1}{7} - \frac{6}{7} \log \frac{6}{7} \right) \\ &+ \frac{7}{14} \left(-\frac{4}{7} \log \frac{4}{7} - \frac{3}{7} \log \frac{3}{7} \right) \\ &= 0.788 \end{aligned}$$

$\text{Gain}(\text{学生})$

$$\begin{aligned} &= \text{Info}(D) - \text{Info}_{\text{学生}}(D) \\ &= 0.940 - 0.788 = 0.152 \end{aligned}$$

确定第一次分裂的属性：按信用划分

年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否


信用好的有6个, 其中3个为“否”

信用一般的有8个, 其中2个为“否”

$$\begin{aligned}\text{Info}_{\text{信用}}(D) &= \frac{6}{14} \left(-\frac{3}{6} \log \frac{3}{6} - \frac{3}{6} \log \frac{3}{6} \right) \\ &+ \frac{8}{14} \left(-\frac{2}{8} \log \frac{2}{8} - \frac{6}{8} \log \frac{6}{8} \right) \\ &= 0.892\end{aligned}$$

$$\begin{aligned}\text{Gain}(\text{信用}) &= \text{Info}(D) - \text{Info}_{\text{信用}}(D) \\ &= 0.940 - 0.892 = 0.048\end{aligned}$$

确定第一次分裂的属性



确定第二次分裂的属性


收入	学生	信用	买了电脑
高	否	一般	否
高	否	好	否
中	否	一般	否
低	是	一般	是
中	是	好	是

“学生”属性具体最高
信息增益，成为分裂属性

$$\begin{aligned}\text{Info}_{\text{收入}}(D) &= 2/5 * (-2/2 * \log 2/2 - 0/2 * \log 0/2) \\ &\quad + 2/5 * (-1/2 * \log 1/2 - 1/2 * \log 1/2) \\ &\quad + 1/5 * (-1/1 * \log 1/1 - 0/1 * \log 0/1) \\ &= 0.400\end{aligned}$$

$$\begin{aligned}\text{Info}_{\text{学生}}(D) &= 3/5 * (-3/3 * \log 3/3 - 0/3 * \log 0/3) \\ &\quad + 2/5 * (-2/2 * \log 2/2 - 0/2 * \log 0/2) \\ &= 0\end{aligned}$$

$$\begin{aligned}\text{Info}_{\text{信用}}(D) &= 3/5 * (-2/3 * \log 2/3 - 1/3 * \log 1/3) \\ &\quad + 2/5 * (-1/2 * \log 1/2 - 1/2 * \log 1/2) \\ &= 0.951\end{aligned}$$



ID3决策树建立算法

- 1 决定分类属性集合;
- 2 对目前的数据表, 建立一个节点N
- 3 如果数据库中的数据都属于同一个类, N就是树叶, 在树叶上标出所属的类(纯的类别)
- 4 如果数据表中没有其他属性可以考虑, 则N也是树叶, 按照少数服从多数的原则在树叶上标出所属类别(不纯的类别)
- 5 否则, 根据信息增益的值选出一个最佳属性作为节点N的测试属性
- 6 节点属性选定后, 对于该属性中的每个值:
从N生成一个分支, 并将数据表中与该分支有关的数据收集形成分支节点的数据表, 在表中删除节点属性那一栏
- 7 如果分支数据表属性非空, 则转1, 运用以上算法从该节点建立子树

西瓜数据集 决策实例




图 4.1 西瓜问题的一棵决策树

决策树学习的目的：为了产生一颗泛化能力强的决策树，即处理未见示例能力强。

西瓜数据集 决策实例

数据集包含17个训练样例：

8个正例（好瓜）占 $p_1 = \frac{8}{17}$

9个反例（坏瓜）占 $p_2 = \frac{9}{17}$

对于二分类任务 $|y| = 2$

以属性“色泽”为例计算其信息增益

根结点的信息熵：

$$\text{Ent}(D) = - \sum_{k=1}^2 p_k \log_2 p_k = - \left(\frac{8}{17} \log_2 \frac{8}{17} + \frac{9}{17} \log_2 \frac{9}{17} \right) = 0.998 .$$

西瓜数据集 决策实例

用“色泽”将根结点划分后获得3个分支结点的信息熵分别为：

$$\text{Ent}(D^1) = - \left(\frac{3}{6} \log_2 \frac{3}{6} + \frac{3}{6} \log_2 \frac{3}{6} \right) = 1.000 ,$$

$$\text{Ent}(D^2) = - \left(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6} \right) = 0.918 ,$$

$$\text{Ent}(D^3) = - \left(\frac{1}{5} \log_2 \frac{1}{5} + \frac{4}{5} \log_2 \frac{4}{5} \right) = 0.722 ,$$

属性“色泽”的信息增益为：

$$\begin{aligned} \text{Gain}(D, \text{色泽}) &= \text{Ent}(D) - \sum_{v=1}^3 \frac{|D^v|}{|D|} \text{Ent}(D^v) \\ &= 0.998 - \left(\frac{6}{17} \times 1.000 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722 \right) \\ &= 0.109 . \end{aligned}$$

西瓜数据集 决策实例

类似的, 我们可计算出其他属性的信息增益:

$\text{Gain}(D, \text{根蒂}) = 0.143$; $\text{Gain}(D, \text{敲声}) = 0.141$;

$\text{Gain}(D, \text{纹理}) = 0.381$; $\text{Gain}(D, \text{脐部}) = 0.289$;

$\text{Gain}(D, \text{触感}) = 0.006$.




图 4.4 在西瓜数据集 2.0 上基于信息增益生成的决策树




图 4.3 基于“纹理”属性对根结点划分

西瓜数据集 决策实例

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

西瓜数据集 决策实例

若把“编号”也作为一个候选划分属性，则属性“编号”的信息增益为：

根结点的信息熵仍为： $Ent(D) = 0.998$

用“编号”将根结点划分后获得17个分支结点的信息熵均为：

$$Ent(D^1) = \cdots = Ent(D^{17}) = -\left(\frac{1}{1}\log_2 \frac{1}{1} + \frac{0}{1}\log_2 \frac{0}{1}\right) = 0$$

则“编号”的信息增益为：

$$Gain(D, \text{编号}) = Ent(D) - \sum_{v=1}^{17} \frac{1}{17} Ent(D^v) = 0.998$$

远大于其他候选属性

信息增益准则对可取值数目较多的属性有所偏好

改进1：信息增益的问题

假设按属性 A 划分 D 中的样本，且属性 A 根据训练数据的观测具有 v 个不同取值 $\{a_1, a_2, \dots, a_j, \dots, a_v\}$ 。

如果 A 是离散值，可依属性 A 将 D 划分为 v 个子集 $\{D_1, D_2, \dots, D_j, \dots, D_v\}$

其中， D_j 为 D 中的样本子集，它们在 A 上具有属性值 a_j

这些划分将对应于从该节点 A 出来的分支。

信息增益度量偏向于对取值较多的属性进行测试，即它倾向于选择 v 较大的属性 A

举个极端的例子：考虑充当唯一标识的属性 PID 。对 PID 的分裂将产生大量划分（与样本个数一样多），每个分类只包含一个样本，且每个划分都是纯的。

$$\begin{aligned} Info_{PID}(D) \\ &= \frac{1}{14} \times \left(-\frac{1}{1} \log_2 \frac{1}{1} \right) \\ &= 0 \end{aligned}$$

对属性 PID 划分得到的信息增益最大，显然，这种划分对分类没有用处。

改进1： 信息增益率

C4.5使用分裂信息(split information)将信息增益规范化

$$SplitInfo_A(D) = -\sum_{j=1}^v \frac{|D_j|}{|D|} \log \frac{|D_j|}{|D|}$$

该值表示数据集D按属性A分裂的v个划分产生的信息

$$GainRatio(A) = \frac{Gain(A)}{SplitInfo_A(D)}$$

选择具有最大信息增益率的属性作为分裂属性

改进1: 信息增益率

年龄	收入	学生	信用	买了电脑
<30	高	否	一般	否
<30	高	否	好	否
30-40	高	否	一般	是
>40	中	否	一般	是
>40	低	是	一般	是
>40	低	是	好	否
30-40	低	是	好	是
<30	中	否	一般	否
<30	低	是	一般	是
>40	中	是	一般	是
<30	中	是	好	是
30-40	中	否	好	是
30-40	高	是	一般	是
>40	中	否	好	否

$$\text{Info}(D) = 0.940$$

$$\text{Info}_{\text{收入}}(D) = 0.911$$

$$\text{Gain}(\text{收入}) = 0.029$$

高收入的有4个
中等收入的有6个
低收入的有4个

$$\begin{aligned} \text{SplitInfo}_{\text{收入}}(D) &= -4/14 * \log 4/14 \\ &\quad - 6/14 * \log 6/14 \\ &\quad - 4/14 * \log 4/14 \\ &= 1.557 \end{aligned}$$

$$\begin{aligned} \text{GainRatio}(\text{收入}) &= \text{Gain}(\text{收入}) / \text{SplitInfo}_{\text{收入}}(D) \\ &= 0.029 / 1.557 = 0.019 \end{aligned}$$

改进2：学习过程中的过度拟合

- 上述的**决策树算法**增长树的每一个分支的**深度**，直到恰好能对训练样例比较完美地分类。
- 实际应用中，当训练样本中**有噪声**或**训练样例的数量太少以至于不能产生目标函数的有代表性的采样**时，该策略可能会遇到困难
- 在以上情况发生时，这个简单的算法产生的树会**过度拟合训练样例** (过度拟合: Over fitting)
- 过度拟合产生的原因：训练样本中**有噪声**，训练样例太小等

改进2：学习过程中的过度拟合

- 过拟合：学习器学习能力过于强大，把训练样本自身的一些特点当作了所有潜在样本都会具有的一般性质，导致泛化性能下降。
- 欠拟合：学习器学习能力低下，对训练样本的一般性质尚未学好。






图 2.1 过拟合、欠拟合的直观类比

过拟合无法彻底避免，只能做到“缓解”。

缺乏代表性样本所导致的过度拟合

哺乳动物分类的训练样例

名称	体温	胎生	4条腿	冬眠	哺乳动物
蝾螈	冷血	N	Y	Y	N
虹鳟	冷血	Y	N	N	N
鹰	恒温	N	N	N	N
弱夜鹰	恒温	N	N	Y	N
鸭嘴兽	恒温	Y	Y	Y	Y




哺乳动物分类的测试样例

名称	体温	胎生	4条腿	冬眠	哺乳动物
人	恒温	Y	N	N	Y
大象	恒温	Y	Y	N	Y
鸽子	恒温	N	N	N	N

按照训练模型。人和大象都不是哺乳动物。决策树作出这样的判断是因为只有一个训练样例具有这些特点（鹰，恒温，不冬眠）被划分为非哺乳动物。

该例清楚表明，当决策树的叶节点没有足够的代表性时，可能会预测错误。


改进3：决策树剪枝



改进3：决策树预剪枝


最直接的方法：
事先限定树的最大生长高度

如果设为3，
则如图剪枝



改进4：决策树后剪枝

训练过程中允许对数据的过度拟合，然后再利用测试集对树进行修剪



剪枝，即通过主动去掉一些分支来降低过拟合的风险。

决策树的剪枝策略

- 预剪枝
- 后剪枝

预剪枝：在决策树生成过程中，对每个结点在划分前先进行估计，若当前结点的划分不能带来决策树泛化性能提升，则停止划分并将当前结点标记为叶结点

后剪枝：先从训练集生成一棵完整的决策树，然后自底向上地对非叶结点进行考察，若将该结点对应的子树替换为叶结点能带来决策树泛化性能提升，则将该子树替换为叶结点。

留出法：将数据集**D**划分为两个互斥的集合：训练集**S**和测试集**T**

$$D = S \cup T \quad \text{且} \quad S \cap T = \emptyset$$

预剪枝

精度：正确分类的样本占所有样本的比例

验证集：4,5,8,9,11,12,13

训练集：好瓜 坏瓜
1,2,3,6,7,10,14,15,16,17





图 4.6 基于表 4.2 生成的预剪枝决策树



预剪枝使得决策树的很多分支都没有“展开”

优点:

- 降低过拟合的风险
- 减少了训练时间开销和测试时间开销

图 4.5 基于表 4.2 生成的未剪枝决策树

不足:

- 基于“贪心”本质禁止某些分支展开，带来了欠拟合的风险

后剪枝

先从训练集生成一棵完整的决策树，然后自底向上地对非叶结点进行考察，若将该结点对应的子树替换为叶结点能带来决策树泛化性能提升，则将该子树替换为叶结点。

训练集: 好瓜 坏瓜
1,2,3,6,7,10,14,15,16,17

验证集: 4,5,8,9,11,12




图 4.5 基于表 4.2 生成的未剪枝决策树 验证集精度: $\frac{3}{7}$

后剪枝决策树




图 4.7 基于表 4.2 生成的后剪枝决策树

- 保留了更多的分支
- 欠拟合风险很小
- 泛化能力优于预剪枝决策树

- 训练时间开销比未减枝和预剪枝决策树大得多

1. 生产完全决策树
2. 所有非叶节点逐一考察

预剪枝决策树




图 4.6 基于表 4.2 生成的预剪枝决策树

改进5：缺失值的处理

表 4.4 西瓜数据集 2.0α

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	-	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	-	是
3	乌黑	蜷缩	-	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	-	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	-	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	-	稍凹	硬滑	是
9	乌黑	-	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	-	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	-	否
12	浅白	蜷缩	-	模糊	平坦	软粘	否
13	-	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	-	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	-	沉闷	稍糊	稍凹	硬滑	否

现实任务中，尤其在属性数目较多时，存在大量样本出现缺失值。
出于成本和隐私的考虑

改进5：缺失值的处理

在某些情况下，可供使用的数据可能缺少某些属性的值，例如

天气	湿度	有雨？	去玩？
晴	70	有	玩
晴	90	有	不玩
晴	85	无	不玩
晴	95	无	不玩
晴	70	无	玩
缺失	90	有	玩
多云	78	无	玩
多云	65	有	玩
多云	75	无	玩
雨	80	有	不玩
雨	70	有	不玩
雨	80	无	玩
雨	80	无	玩
雨	96	无	玩


一种简单的办法是赋予它该属性最常见的值，例如将“晴”或“雨”赋予第6个实例的天气属性

一种更复杂的策略是为A的每个可能值赋予一个概率

改进5：缺失值的处理

- 建树过程（学习过程）
 - 选定训练样本实例有缺失值，如何知道要将其分配到哪个分支？
- 分类过程（测试过程或者工作过程）
 - 待分类实例有缺失值，如何测试该实例属于哪个分支？

(天气=缺失, 温度=72, 湿度=90...)



改进5： C4.5中缺失值的处理 - 建树过程（学习过程）

$$\text{Gain}(A) = F (\text{Info}(D) - \text{Info}_A(D))$$

其中 F 为属性值未缺失的实例所占比例；

计算 $\text{Info}(D)$ 和 $\text{Info}_A(D)$ 时忽略属性值缺失的实例

$$\text{Info}(D)$$

$$= -8/13 \times \log(8/13) - 5/13 \times \log(5/13)$$

$$= 0.961 \text{ bits}$$

$$\text{Info}_{\text{天气}}(D)$$

$$\begin{aligned} &= 5/13 \times (-2/5 \log(2/5) - 3/5 \times \log(3/5)) \\ &\quad + 3/13 \times (-3/3 \log(3/3) - 0/3 \times \log(0/3)) \\ &\quad + 5/13 \times (-3/5 \log(3/5) - 2/5 \times \log(2/5)) \\ &= 0.747 \text{ bits} \end{aligned}$$

$$\text{Gain}(\text{天气})$$

$$\begin{aligned} &= \mathbf{13/14} \times (0.961 - 0.747) \\ &= 0.199 \text{ bits} \end{aligned}$$

天气	湿度	有雨？	去玩？
晴	70	有	玩
晴	90	有	不玩
晴	85	无	不玩
晴	95	无	不玩
晴	70	无	玩
缺失	90	有	玩
多云	78	无	玩
多云	65	有	玩
多云	75	无	玩
雨	80	有	不玩
雨	70	有	不玩
雨	80	无	玩
雨	80	无	玩
雨	96	无	玩

改进5： C4.5中缺失值的处理 - 建树过程（学习过程）

计算 **SplitInfo** 时，将缺失的属性值当作一个正常值进行计算，
本例中，当作天气有四个值，分别是晴, 多云, 雨, ?，再计算其 **SplitInfo**

天气	湿度	有雨?	去玩?
晴	70	有	玩
晴	90	有	不玩
晴	85	无	不玩
晴	95	无	不玩
晴	70	无	玩
缺失	90	有	玩
多云	78	无	玩
多云	65	有	玩
多云	75	无	玩
雨	80	有	不玩
雨	70	有	不玩
雨	80	无	玩
雨	80	无	玩
雨	96	无	玩

$\text{SplitInfo}_{\text{天气}}(D)$

$= - 5/14 \times \log(5/14) \Rightarrow$ 晴

$- 3/14 \times \log(3/14) \Rightarrow$ 多云

$- 5/14 \times \log(5/14) \Rightarrow$ 雨

$- 1/14 \times \log(1/14) \Rightarrow$ 缺失

$= 1.809 \text{ bits}$

$\text{GainRatio}(\text{天气})$

$= \text{Gain}(\text{天气}) / \text{SplitInfo}_{\text{天气}}(D)$

$= 0.199 / 1.809$