

第4章 线性模型—线性判别

浙江理工大学 曹丽

办公室 10-541



实例1



识别过程:

- (1) 数据获取: 架设一个摄像机, 采集一些样本图像, 获取样本数据
- (2) 预处理: 去噪声, 用一个分割操作鱼和鱼之间, 鱼和背景之间分开
- (3) 特征的提取和选择: 对单个鱼的特征进行特征选择, 从而通过测量某些特征来减少信息量 (长度、亮度、宽度、鱼翅的数量和形状、嘴的位置)
- (4) 分类决策: 把特征送入决策分类器

实例1




实例2

19名男女同学进行体检，测量了身高和体重。但事后发现有4名学生忘记填写性别，试问：这4位同学是男是女？

编 号	身高(cm)	体重(kg)	性 别	编 号	身高(cm)	体重(kg)	性 别
1	170	68	男	11	140	62	男
2	130	66	女	12	150	64	女
3	180	71	男	13	120	66	女
4	190	73	男	14	150	66	男
5	160	70	女	15	130	65	男
6	150	66	男	α	140	70	?
7	190	68	男	β	150	60	?
8	210	76	男	γ	145	65	?
9	100	58	女	δ	160	75	?
10	170	75	男				

实例2



从图中训练样本的分别情况，找出男女两类特征各自的聚类特点，从而求取一个判别函数（直线或者曲线）

只要给出待分类的模式特征的数值，看他在特征平面上落在判别函数的哪一侧，就可以判别是男是女了？

两类问题线性判别函数的一般表达式

$$\begin{aligned} g(\mathbf{X}) &= w_1 x_1 + w_2 x_2 + \cdots + w_d x_d + w_{d+1} \\ &= \mathbf{w}_0^T \mathbf{X} + w_{d+1} \end{aligned}$$

- $\mathbf{X}$ 是 d 维特征向量（样本向量）， $\mathbf{X} = [x_1, x_2, \dots, x_d]^T$ ；
- w_i 是加权因子；
- $\mathbf{w}_0$ 称为权向量， $\mathbf{w}_0 = [w_1, w_2, \dots, w_d]^T$ ；
- w_{d+1} 是个常数，称为阈值权。

两类问题的分类器

$$g(\mathbf{X}) = \mathbf{w}_0^T \mathbf{X} + w_{d+1}$$

- $g(\mathbf{X}) > 0$, 则决策 $\mathbf{X} \in \omega_1$;
- $g(\mathbf{X}) < 0$, 则决策 $\mathbf{X} \in \omega_2$;
- $g(\mathbf{X}) = 0$, 可将 $\mathbf{X}$ 任意分到某一类或拒绝。

$g(\mathbf{X})$ 为线性函数, 分类器被称为线性分类器。

决策面方程: $g(\mathbf{X}) = 0$

- 把归类于 ω_1 的样本与归类于 ω_2 的样本分割开来。

线性判别函数的估计问题

$$\begin{aligned} g(\mathbf{X}) &= w_1 x_1 + w_2 x_2 + \cdots + w_d x_d + w_{d+1} \\ &= \mathbf{w}_0^T \mathbf{X} + w_{d+1} \end{aligned}$$

- 已知样本集，用样本去估计 w_0 、 w_{d+1} 。
- 估计 w_0 、 w_{d+1} 时，针对不同实际情况应提出不同设计要求，使设计的分类器尽可能好地满足这些要求。
- 由于所提要求不同，设计结果也将各异。

权向量和决策面之间的关系

线性分类器的决策面 H 是超平面。

设 X_1 、 X_2 都在决策面 H 上，则有

$$\mathbf{w}_0^T \mathbf{X}_1 + w_{d+1} = \mathbf{w}_0^T \mathbf{X}_2 + w_{d+1}$$

$$\mathbf{w}_0^T (\mathbf{X}_1 - \mathbf{X}_2) = 0$$

w_0 和超平面 H 上任一向量正交，即： w_0 是 H 的法向量。

线性分类器与超平面

利用线性判别函数进行决策，就是用一个超平面把特征空间分割成两个决策区域。

超平面的方向由权向量 w 确定，位置由阈值权 w_{d+1} 确定。

判别函数 $g(X)$ 正比于 X 点到超平面 H 的代数距离。

当 X 在 H 正侧时， $g(X)>0$ ；在负侧时， $g(X)<0$ 。

线性分类器的设计步骤

1. 构成训练样本集 X ， X 中每个样本的属性是预知的。
2. 确定一个准则函数 J ，且满足：
 - J 是样本集 X 和 w_0 、 w_{d+1} 的函数，记为： $J(w, X)$ J 的值反映分类器的性能，且存在 w^* 使分类器性能最优。
3. 设计求解 w 的最优算法，得到解向量 w^* 。

求得 w^* ，就完成训练任务，得到判别函数： $g(X) = w^{*T}X$


对待分类样本 X_k ，计算 $g(X_k)$ ，然后进行判断。

线性判别函数的局限性


- 在一维空间中，没有任何一个线性函数能解决下述划分问题（黑红各代表一类数据）。



- 建立二次判别函数： $g(X)=(X-a)(X-b)$ ，决策规则同上。



Fisher线性判别




- 利用已知类别个体的指标构造判别式
（同类差别较小，不同类别差别较大）
按照判别式的值判断新个体的值。
- **原理：** 找到一个最合适的投影轴，使两类样本在该轴上投影的距离尽可能远，而每一类样本的投影尽可能紧凑，从而使两类分类效果为最佳。
- **目的：** 降维，在低维空间中进行分割。

Fisher法要解决的基本问题


问题： 在 d 维空间分得很好的样本投影到一维空间后，可能混到一起而无法分割。

一般，总可以找到某个方向，使得该方向的直线上，样本的投影能分开的最好。

问题转换：找到一条最好的、最易于分类的投影线



Fisher判别图例



Fisher准则的描述： 用投影后数据的统计性质——均值和离散度的函数作为判别优劣的标准。

d维X空间，基本参量的定义

□ 各类样本的均值向量 M_i
$$M_i = \frac{1}{n_i} \sum_{X_k \in \mathcal{X}_i} X_k, \quad k=1, \dots, n_i \quad i=1, 2$$

□ 样本类内离散度矩阵 S_i 和总类内离散度矩阵 S_w

$$S_i = \sum_{X_k \in \mathcal{X}_i} (X_k - M_i)(X_k - M_i)^T, \quad k=1, \dots, n_i \quad i=1, 2$$

□ 样本类间离散度矩阵 S_b
$$S_w = S_1 + S_2$$

$$S_b = (M_1 - M_2)(M_1 - M_2)^T$$

一维Y空间，基本参量的定义

□ 各类样本均值 $\tilde{m}_i = \frac{1}{n_i} \sum_{y_k \in \mathcal{Y}_i} y_k, \quad k=1, \dots, n_i \quad i=1, 2$

□ 样本类内离散度矩阵和总类内离散度矩阵

$$\tilde{S}_i^2 = \sum_{y_k \in \mathcal{Y}_i} (y_k - \tilde{m}_i)^2, \quad k=1, \dots, n_i \quad i=1, 2$$

$$\tilde{S}_w = \tilde{S}_1^2 + \tilde{S}_2^2$$

Fisher准则函数

□ 希望在映射后两类平均值之间的距离越大越好，而各类的样本类内离散度越小越好。

□ 定义Fisher准则函数：

$$J_F(\mathbf{w}) = \frac{|\tilde{m}_1 - \tilde{m}_2|^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

□ 使 J_F 最大的解析解 $\mathbf{w}^*$ 就是最佳解向量，也就是Fisher的线性判别式。

$JF(\mathbf{w})$ 的变换

$$\left. \begin{aligned} \tilde{m}_i &= \frac{1}{n_i} \sum_{y \in \mathcal{Y}_i} y \\ y &= \mathbf{w}^T \mathbf{X} \end{aligned} \right\} \Rightarrow \tilde{m}_i = \frac{1}{n_i} \sum_{\mathbf{X} \in \mathcal{X}_i} \mathbf{w}^T \mathbf{X} = \mathbf{w}^T \frac{1}{n_i} \sum_{\mathbf{X} \in \mathcal{X}_i} \mathbf{X} \left. \begin{aligned} &\Rightarrow \tilde{m}_i = \mathbf{w}^T \mathbf{M}_i \\ \mathbf{M}_i &= \frac{1}{n_i} \sum_{\mathbf{X} \in \mathcal{X}_i} \mathbf{X} \end{aligned} \right\}$$

$$J_F(\mathbf{w}) = \frac{|\tilde{m}_1 - \tilde{m}_2|^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

$$\left. \begin{aligned} |\tilde{m}_1 - \tilde{m}_2|^2 &= \left| \mathbf{w}^T \mathbf{M}_1 - \mathbf{w}^T \mathbf{M}_2 \right|^2 = \mathbf{w}^T (\mathbf{M}_1 - \mathbf{M}_2) (\mathbf{M}_1 - \mathbf{M}_2)^T \mathbf{w} \\ \mathbf{S}_b &= (\mathbf{M}_1 - \mathbf{M}_2) (\mathbf{M}_1 - \mathbf{M}_2)^T \end{aligned} \right\} \Rightarrow$$

$$|\tilde{m}_1 - \tilde{m}_2|^2 = \mathbf{w}^T \mathbf{S}_b \mathbf{w}$$

$J_F(\mathbf{w})$ 的变换

$$J_F(\mathbf{w}) = \frac{|\tilde{m}_1 - \tilde{m}_2|^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

$$\tilde{S}_i = \sum_{y \in \psi_i} (y - \tilde{m}_i)^2$$

$$= \sum_{x \in K_i} (\mathbf{w}^T \mathbf{x} - \mathbf{w}^T \mathbf{m}_i)^2$$

$$= \mathbf{w}^T \left[\sum_{x \in K_i} (\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^T \right] \mathbf{w}$$

$$= \mathbf{w}^T S_i \mathbf{w}$$

$$\tilde{S}_1 + \tilde{S}_2 = \mathbf{w}^T (S_1 + S_2) \mathbf{w} = \mathbf{w}^T S_w \mathbf{w}$$

$$\Rightarrow J_F(\mathbf{w}) = \frac{|\tilde{m}_1 - \tilde{m}_2|^2}{\tilde{S}_1^2 + \tilde{S}_2^2} = \frac{\mathbf{w}^T S_b \mathbf{w}}{\mathbf{w}^T S_w \mathbf{w}}$$

w^* 的求解

- 令分母不等于0，定义Lagrange函数乘子法

$$J_F(\mathbf{w}) = \frac{\mathbf{w}^T S_b \mathbf{w}}{\mathbf{w}^T S_w \mathbf{w}}$$

$$L(\mathbf{w}, \lambda) = \mathbf{w}^T S_b \mathbf{w} - \lambda (\mathbf{w}^T S_w \mathbf{w} - c)$$

- 令偏导数等于零：

$$\frac{\partial L(\mathbf{w}, \lambda)}{\partial \mathbf{w}} = 0$$
$$\Downarrow$$

$$S_b \mathbf{w}^* - \lambda S_w \mathbf{w}^* = 0$$

w^* 的求解

$$S_b \mathbf{w}^* - \lambda S_w \mathbf{w}^* = 0$$

$$S_i = \sum_{\mathbf{X}_k \in \mathcal{X}_i} (\mathbf{X}_k - \mathbf{M}_i)(\mathbf{X}_k - \mathbf{M}_i)^T, \quad i=1,2 \quad k=1,\dots,n$$

$$S_w = S_1 + S_2$$

- S_w 比例于 d 维特征的样本协方差矩阵，它是对称的和半正定的，当样本数目 $n > d$ 时，通常是非奇异的。所以有：

$$S_w^{-1} S_b \mathbf{w}^* = \lambda \mathbf{w}^* \longrightarrow \mathbf{w}^* = S_w^{-1} (\mathbf{M}_1 - \mathbf{M}_2)$$

这就是Fisher判别准则下的最优投影方向了！

判别函数的确定

需要注意的是：

Fisher线性判别函数最优的解本身只给出了一个投影方向，并没有给出我们要的决策面，想要得到决策面，需要在投影后的一维空间上确定一个分类阈值 w_0 。若不考虑先验概率的不同，则可以采用 $w_0 = \tilde{m}$ ，其中 $\tilde{m}$ 是所有样本在投影后的均值。[直观的解釋](#)，Fisher线性判别就是把待决策的样本投影到Fisher线性判别的方向上，通过与分类均值投影的平分点进行比较做出分类判别。在先验概率相同的情况下，以该评分点为两类样本的分界点；在先验概率不同的情况下，分界点向先验概率小的一侧偏移。

阈值 w_0 的选取：

1. d 和 N 很大时， y 近似正态分布，可在 Y 空间内用贝叶斯分类器

2. 经验，如：

$$w_0 = -\frac{1}{2} (\tilde{m}_1 + \tilde{m}_2)$$

$$w_0 = -\tilde{m}$$

$$w_0 = -\frac{1}{2} (\tilde{m}_1 + \tilde{m}_2) - \frac{1}{N_1 + N_2 - 2} \ln \frac{P(w_1)}{P(w_2)}$$

3. 在实际工作中还可以对 w_0 进行逐次修正的方式，选择不同的 w_0 值，计算其对训练样本集的错误率，找到错误率较小的 w_0 值

Fisher算法实现步骤

1. 把来自两类 ω_1/ω_2 的训练样本集 X 分成与 ω_1 和 ω_2 分别对应的训练样本子集 X_1 和 X_2 。

$$\mathbf{M}_i = \frac{1}{n_i} \sum_{X_k \in \mathcal{X}_i} \mathbf{X}_k, \quad i=1,2 \quad k=1,\dots,n$$

2. 计算各类样本的均值向量

3. 计算样本类内离散度矩阵 $\mathbf{S}_i = \sum_{X_k \in \mathcal{X}_i} (\mathbf{X}_k - \mathbf{M}_i)(\mathbf{X}_k - \mathbf{M}_i)^T, \quad i=1,2 \quad k=1,\dots,n$

4. 计算总类内离散度矩阵 $\mathbf{S}_w = \mathbf{S}_1 + \mathbf{S}_2$

5. 计算 $\mathbf{S}_w$ 的逆矩阵 $\mathbf{S}_w^{-1}$

6. 求解 $\mathbf{w}^* = \mathbf{S}_w^{-1}(\mathbf{M}_1 - \mathbf{M}_2)$

四、实例分析

例1 人文发展指数是联合国开发计划署于1990年5月发表的第一份《人类发展报告》中公布的。该报告建议，目前对人文发展的衡量应当以人生的三大要素为重点，**衡量人生三大要素的指示指标分别要用出生时的预期寿命、成人识字率和实际人均GDP**，将以上三个指示指标的数值合成为一个复合指数，即为人文发展指数。

今从1995年世界各国人文发展指数的排序中，选取高发展水平、中等发展水平的国家各五个作为两组样品，另选四个国家作为待判样品作距离判别分析。

类别	序号	国家名称	出生时的 预期寿命 (岁) x_1	成人识字率 (%) 1992 x_2	调整后人均 GDP 1992 x_3
第一类 (高发展水平国家)	1	美国	76	99	5374
	2	日本	79.5	99	5359
	3	瑞士	78	99	5372
	4	阿根廷	72.1	95.9	5242
	5	阿联酋	73.8	77.7	5370
第二类 (中等发展水平国家)	6	保加利亚	71.2	93	4250
	7	古巴	75.3	94.9	3412
	8	巴拉圭	70	91.2	3390
	9	格鲁吉亚	72.8	99	2300
	10	南非	62.9	80.6	3799
待判样品	11	中国	68.5	79.3	1950
	12	罗马尼亚	69.9	96.9	2840
	13	希腊	77.6	93.8	5233
	14	哥伦比亚	69.3	90.3	5158

本例中变量个数 $p=3$ ，两类总体各有 5 个样品，即 $n_1 = n_2 = 5$ ，有 4 个待判样品，假定两总体协差阵相等。

两组线性判别的计算过程如下：

1. 计算样本均值
2. 计算样本协差阵
3. 建立判别函数
4. 计算判别临界值
5. 对已知类别的样品判别归类
6. 待判样品判别结果

序号	国 家	判别函数 y 的值	原类号	判归类别
1	美 国	12.2122	1	1
2	日 本	12.4812	1	1
3	瑞 士	12.3731	1	1
4	阿根廷	11.7450	1	1
5	阿联酋	11.9960	1	1
6	保加利亚	10.5851	2	2
7	古 巴	10.0078	2	2
8	巴拉圭	9.5460	2	2
9	格鲁吉亚	8.5968	2	2
10	南 非	9.3973	2	2

序号	国 家	判别函数 y 的值	判属类别
11	中 国	7.8342	2
12	罗马尼亚	8.9464	2
13	希 腊	12.1809	1
14	哥伦比亚	11.4169	1