

第4章 线性模型—线性回归

浙江理工大学 曹丽

办公室 10-541

回归与分类

分类是机器学习的一项主要任务！

分类和回归在本质上一样的，都是关于预测的问题。分类顾名思义就是预测A类、B类还是C类。或者是0还是1等。而回归则是预测这个值具体是多少？给出已知a值预测出对应值是b值。

分类和回归的关键区别是目标属性是否连续。分类的目标属性必须是离散的，回归的目标属性必须是连续。

线性回归的简介

⑩ 机器学习

⑩ 监督学习

⑩ 无监督学习

⑩ 强化学习


⑩ 回归分析

⑩ 线性回归：简单线性回归、多元线性回归

⑩ 非线性回归

⑩ 应用：预测连续目标变量

- 公司未来几个月的销售额
- 房价变化与因素的关系



⑩ 房价与房间数线性直线

回归的由来

⑩英国人类学家 F. Galton 首次在《自然遗传》一书中，提出并阐明了“相关”和“相关系数”两个概念，为相关论奠定了基础。

⑩其后，他和英国统计学家Karl Pearson 对上千个家庭的身高，臂长做了测量，发现了一种现象。




回归问题的应用场景

回归分析属于有监督学习，简单有效，应用十分广泛：


Machine learning goal: Estimate CTR for a given user/ad pair.

$f(\text{user}, \text{ad}) = \text{CTR}$



回归分析

回归分析研究的主要是因变量（目标）和自变量（经验）之间的依据关系。按照关系类型，又可分为线性回归和非线性回归分析。学习过程如右图所示：



⑩ 线性回归学习过程

线性回归的原理


⑩ 在统计学中，线性回归（Linear Regression）是利用称为线性回归方程的最小平方差函数对一个或多个自变量和因变量之间关系进行建模的一种回归分析。这种函数是一个或多个称为回归系数的模型参数的线性组合。只有一个自变量的情况称为一元线性回归，大于一个自变量情况的叫做多元线性回归。（这反过来又应当由多个相关的因变量预测的多元线性回归区别，而不是一个单一的标量变量。）

⑩ 在线性回归中，数据使用线性预测函数来建模，并且未知的模型参数也是通过数据来估计。**这些模型被叫做线性模型**。线性回归模型经常用最小二乘逼近来拟合，但他们也可能用别的方法来拟合，比如用最小化“拟合缺陷”在一些其他规范里（比如最小绝对误差回归）。

线性回归的原理

线性回归

是一种通过属性的线性组合来进行预测的线性模型，其目的是找到一条直线或者一个平面或者更高维的超平面，使得预测值与真实值之间的误差最小化。



线性回归曲线

线性回归（单个特征）

简单线性回归是针对单个特征（x）和连续响应值（y）之间的关系建模：


$$y = wx + b$$

w：特征向量x的权重

b：偏置项

目标

学习模型中的w和b，以描述特征x与响应值y之间的关系，然后预测训练集中未见过的新的响应变量。



线性回归示意图

一元线性回归

一元线性回归即输入只有一元

$$f(x) = wx_i + b \text{ 使得 } f(x_i) \simeq y_i$$

离散属性的处理：若有“序”(order)，则连续化；
否则，转化为k维向量

$$\begin{aligned} \text{令均方误差最小化, 有 } (w^*, b^*) &= \arg \min_{(w, b)} \sum_{i=1}^m (f(x_i) - y_i)^2 \\ &= \arg \min_{(w, b)} \sum_{i=1}^m (y_i - wx_i - b)^2 \end{aligned}$$

$$\text{对 } E_{(w, b)} = \sum_{i=1}^m (y_i - wx_i - b)^2 \text{ 进行最小二乘参数估计}$$

©要做小事

最小二乘法

定义：试图找到一条直线，使得所有样本到直线的欧式距离之和最小；

最小：保证各个观测点与估计点的距离平方和最小；

二乘：用平方度量观测点与估计点的距离。

最小二乘法

➤ 最小二乘法求回归系数


对于数据集中不同的点，我们试图学到：

$f(x_i) = wx_i + b$, 使得 $f(x_i) \approx y_i$ (y_i 为真实值)

如何计算最优的 w 和 b ，关键在于如何衡量 $f(x)$ 与 y 之间的差别。**最小二乘法就是试图找到一条直线，使所有样本到直线的欧式距离之和最小。** 欧式距离与均方误差相对应，即：

$$(w^*, b^*) = \operatorname{argmin} \sum_{i=1}^m (f(x_i) - y_i)^2$$
$$= \operatorname{argmin} \sum_{i=1}^m (y_i - wx_i - b)^2$$

求解 w 和 b 使得 $E_{(w,b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$ 最小化的过程，**称为线性回归模型的最小二乘“参数估计”**。



不同系数的回归曲线

最小二乘法

求解最优解过程

分别对 ω 和 b 求导：

$$\frac{\partial E(\omega, b)}{\partial \omega} = 2(\omega \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i)$$

$$\frac{\partial E(\omega, b)}{\partial b} = 2(mb - \sum_{i=1}^m (y_i - \omega x_i))$$

令导数为0，得到闭式解：

$$\omega = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} (\sum_{i=1}^m x_i)^2} \quad b = \frac{1}{m} \sum_{i=1}^m (y_i - \omega x_i)$$

线性回归（多个特征）

将单个特征推广到多个特征，针对多个特征（X）和连续响应值（y）之间的关系建模：


$$y = \mathbf{W}^T \mathbf{X}$$

$$\mathbf{W}^T = [w_0 \ w_1 \ \cdots \ w_{D-1} \ w_D]$$

$$\mathbf{X}^T = [1 \ x_1 \ x_2 \ \cdots \ x_D] : \text{维度为D的特征向量}$$

$$y = \mathbf{W}^T \mathbf{X} = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_D x_D$$

$$y = w_0 + w_1 x_1 + w_2 x_2$$



二元线性回归拟合平面

目标

学习模型中的W，以描述多个特征X与响应值y之间的关系，然后预测训练集中未见过的新响应变量。

多元线性回归

m 代表训练集中样本的数量

n 代表特征的数量

x 代表特征/输入变量

y 代表目标变量/输出变量

(x, y) 代表训练集中的样本

$(x^{(i)}, y^{(i)})$ 代表第 i 个观察样本

h 代表学习算法的解决方案或函数也称为假设 (**hypothesis**)

$\hat{y} = h(x)$, 代表预测的值

建筑面积	总层数	楼层	实用面积	房价
143.7	31	10	105	36200
162.2	31	8	118	37000
199.5	10	10	170	42500
96.5	31	13	74	31200
.....				

$x^{(i)}$ 是特征矩阵中的第 i 行, 是一个**向量**。

上图的: $x^{(2)} = \begin{bmatrix} 162.2 \\ 31 \\ 8 \\ 118 \end{bmatrix}$ $y^{(2)} = 37000$

$x_j^{(i)}$ 代表特征矩阵中第 i 行的第 j 个特征

上图的 $x_2^{(2)} = 31, x_3^{(2)} = 8$

多元线性回归

上面所述，一个属性对应一个输出的求解过程，接下来，我们讨论当有多个属性的求解过程。

给定有d个属性描述的示例表示为 $x = (x_1; x_2; \dots; x_d)$ ， $f(x) = wx + b$ 需要改写成：

$$f(x) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b$$

一般向量形式：

$$f(x) = w^T x + b$$

例如，从右表西瓜集可以得出：判断一个西瓜是否为好瓜，取决于三个属于色泽、根蒂和敲声。

我们可以根据上面的形式建立这样的线性模型：

$$f_{\text{好瓜}}(x) = 0.2 \cdot x_{\text{色泽}} + 0.5 \cdot x_{\text{根蒂}} + 0.3 \cdot x_{\text{敲声}} + 1$$

表 1.1 西瓜数据集

编号	色泽	根蒂	敲声	好瓜
1	青绿	蜷缩	浊响	是
2	乌黑	蜷缩	浊响	是
3	青绿	硬挺	清脆	否
4	乌黑	稍蜷	沉闷	否

多元线性回归

要找到一组 $w(w_0, w_1, w_2, \dots, w_n)$ ，使得 $J(w) = \frac{1}{2} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$

(残差平方和) 最小，即最小化: $\frac{\partial J(w)}{\partial w}$

将向量表达形式转为矩阵表达形式，则有 $J(w) = \frac{1}{2} (Xw - Y)^2$ ，其中 X 为 m 行 $n + 1$ 列的矩阵（ m 为样本个数， n 为特征个数）， w 为 $n + 1$ 行 1 列的矩阵（包含了 w_0 ）， Y 为 m 行 1 列的矩阵，则 $J(w) = \frac{1}{2} (Xw - Y)^2 = \frac{1}{2} (Xw - Y)^T (Xw - Y)$

$$X = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & x_3^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & x_3^{(2)} & \dots & x_n^{(2)} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & x_3^{(m)} & \dots & x_n^{(m)} \end{bmatrix} \quad Y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \dots \\ y^{(m)} \end{bmatrix}$$

需要用到向量平方的性质:

$$\sum_i z_i^2 = z^T z$$

多元线性回归

为最小化，接下来对 $J(w)$ 偏导，

$$\frac{\partial J(w)}{\partial w} = \frac{1}{2} \frac{\partial}{\partial w} (Xw - Y)^T (Xw - Y) = \frac{1}{2} \frac{\partial}{\partial w} (w^T X^T X w - Y^T X w - w^T X^T Y + Y^T Y)$$

由于中间两项互为转置：

$$\frac{\partial J(w)}{\partial w} = \frac{1}{2} \frac{\partial}{\partial w} (w^T X^T X w - 2w^T X^T Y + Y^T Y) = \frac{1}{2} (2X^T X w - 2X^T Y + 0)$$

$$= X^T X w - X^T Y$$

$$\text{令 } \frac{\partial J(w)}{\partial w} = 0,$$

$$\text{则有 } w = (X^T X)^{-1} X^T Y$$

需要用到以下几个矩阵的求导法则：

$$\frac{dX^T X}{dX} = 2X \quad \frac{dAX}{dX} = A^T$$

$$\frac{\partial X^T A X}{\partial X} = (A + A^T)X, \text{ 若 } A \text{ 为对称阵, } \frac{\partial X^T A X}{\partial X} = 2AX$$

线性回归的例子


假设有一个房屋销售的数据如下：

房屋售价表

面积（平方米）	销售价钱（万元）
123	250
150	320
87	160
102	220

⑩如果来了一个新的面积，假设在售价格的记录中没有的，怎么处理？

⑩解决方法：用一条曲线去尽量准的拟合这些数据，然后如果有新的数据输入过来，我们可以在将曲线上这个点对应的值返回。如果用一条直线去拟合，如下图所示。




线性拟合曲线

对数据集中的非线性关系建模

如果特征变量和响应变量之间的关系，违背了“线性假设”，呈现明显的非线性关系，可采用以下方式建模：

- 多项式回归模型： $y = w_0 + w_1x + w_2x^2 + \dots + w_dx^d$
- 根据经验判断其他可能的关系进行建模
- 随机森林
- 案例：对响应变量MEDV（房价）和特征变量LSTAT（人口的地位低于某个百分点）之间的关系建模




⑩ 房价和LSTAT关系

多项式回归

⑩以 $h(x) = \theta_0 + \theta_1 x + \theta_2 x^2$ 形式的模型为例讲解：将 x^2 看为一个元，则可化简为 $h(x) = w_0 + w_1 x_1 + w_2 x_2$ 。

$$\begin{aligned} L(\mathbf{w}) &= \frac{1}{N} \sum_{i=1}^N L(y^{(i)}, f(\mathbf{x}^{(i)}; \mathbf{w})) \\ &= \frac{1}{N} \sum_{n=1}^N (y^{(i)} - (w_0 + w_1 x_1^{(i)} + w_2 x_2^{(i)}))^2 \end{aligned}$$



多项式回归模型的实现

现在通过具体的例子将多项式回归应用于住房数据集。使用二次和三次多项式构建MEDV（房价）和LSTAT（低地位人口所占百分点）之间关系的模型，并将它与线性拟合进行比较，示例如下：

```
X = df[['LSTAT']].values
```


```
y = df['MEDV'].values
```

```
regr = LinearRegression()
```

```
quadratic =  
PolynomialFeatures(degree=2)
```

```
X_quad = quadratic.fit_transform(X)
```


```
regr = regr.fit(X_quad, y)
```



多项式回归拟合曲线

评估回归模型的性能

- 给定一个测试集，用模型对测试集中的每一个样本进行预测，并根据预测结果评价模型好坏。




绘制残差图

- ⑩ 残差图实质就是计算预测值与真实值之间的偏差。
- ⑩ 这里寻找13个特征x与房价y之间的关系。训练集70%，测试集30%。
- ⑩ 由于是超平面，选择使用绘制残差图的方法观察模型。

绘制残差图

```
plt.scatter(y_train_pred, y_train_pred - y_train,  
            c='steelblue', marker='o', edgecolor='white',  
            label='Training data')  
plt.scatter(y_test_pred, y_test_pred - y_test,  
            c='limegreen', marker='s', edgecolor='white',  
            label='Test data')
```



绘制好的残差图

均方误差

均方误差： MSE (Mean Square Error) ，反应了预测值偏离真实值的程度

$$MSE = \frac{1}{n} \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2$$

$\hat{y}^{(i)}$ 为预测值
 $y^{(i)}$ 为真实值

scikit-learn提供计算MSE的函数供调用，示例如下：

```
from sklearn.metrics import mean_squared_error

print('MSE train: %.3f, test: %.3f' % (
    mean_squared_error(y_train, y_train_pred),
    mean_squared_error(y_test, y_test_pred)))
```


报告决定系数

报告决定系数R²：取值范围0~1之间，反应了响应值y的波动中有多少百分比能被特征x的波动所描述。

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{\frac{1}{n} \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2}{\frac{1}{n} \sum_{i=1}^n (y^{(i)} - \bar{y})^2} = 1 - \frac{MSE}{\text{Var}(y)}$$

SSE：残差平方和

SST：总离差平方和

$\bar{y}$ ：真实观测值的平均值

```
from sklearn.metrics import r2_score
```

```
print('R^2 train: %.3f, test: %.3f' % (
    r2_score(y_train, y_train_pred),
    r2_score(y_test, y_test_pred)))
```

线性回归案例（Python线性回归算法实现）

数据集：北京市空气质量数据.xlsx。

要求：建立PM2.5 预测的一元线性回归模型，其中输入变量为CO，输出变量为PM2.5；建立多元线性回归模型对PM2.5 进行预测，输入变量为（CO和SO2），输出变量为PM2.5，输出回归模型，评估模型表现。

北京市空气质量数据表

日期	AQI	质量等	PM2.5	PM10	SO2	CO	NO2	O3
2014/1/1	81	良	45	111	28	1.5	62	52
2014/1/2	145	轻度污染	111	168	69	3.4	93	14
2014/1/3	74	良	47	98	29	1.3	52	56
2014/1/4	149	轻度污染	114	147	40	2.8	75	14
2014/1/5	119	轻度污染	91	117	36	2.3	67	44
2014/1/6	182	中度污染	138	158	46	2.4	68	12
2014/1/7	145	轻度污染	111	125	34	2	60	43
2014/1/8	27	优	15	25	13	0.5	21	53
2014/1/9	46	优	27	46	19	0.8	35	53
2014/1/10	85	良	63	94	53	1.9	71	19
2014/1/11	139	轻度污染	106	128	76	2.8	90	11
2014/1/12	47	优	27	47	27	0.7	39	59
2014/1/13	109	轻度污染	82	107	67	2.3	78	20
2014/1/14	108	轻度污染	82	108	68	2.4	74	24
2014/1/15	125	轻度污染	95	117	66	2.7	84	18
2014/1/16	402	严重污染	353	384	109	4.6	123	20
2014/1/17	215	重度污染	165	194	67	2.4	76	30
2014/1/18	99	良	74	81	42	1.5	61	36
2014/1/19	151	中度污染	115	186	71	2.5	72	41
2014/1/20	35	优	8	35	6	0.3	15	65
2014/1/21	26	优	18	25	27	0.7	34	50
2014/1/22	150	轻度污染	115	138	75	2.2	93	16

线性回归案例（Python线性回归算法实现）

实现步骤：

- (1) 导入Scikit-learn提供的线性回归模块`sklearn.linear_model`.
- (2) 使用Pandas库读取数据文件
- (3) 进行回归分析（单因子模型和多因子模型）
- (4) 打印输出回归模型参数和回归方程
- (5) 可视化回归结果，并对新样本点进行预测
- (6) 计算回归模型MES和R2_score指标，并分别比较（单因子模型和多因子模型）的指标差异，并作出分析。

线性回归案例（Python线性回归算法实现）

实现结果：

```
predictions = logisticRegre.predict(X_test[0:10])
#输出真实的数字
print(y_test[0:10])
#输出预测的数字
print(predictions)
#准确率
score = logisticRegre.score(X_test, y_test)
#输出准确率
print(score)
```

```
[9 9 0 2 4 5 7 4 7 2]
[9 9 0 2 4 5 7 4 7 2]
0.975925925925926
```

```
##多元回归
X=data[['SO2','CO']]
y=data['PM2.5']
modelLR=LM.LinearRegression()
modelLR.fit(X,y)
print("多元回归模型的截距项:%f"%modelLR.intercept_)
print("多元回归模型的回归系数:",modelLR.coef_)
print("多元回归模型MSE:%f"%(sum((y-modelLR.predict(X))**2)/len(y)))
```

```
多元回归模型的截距项:-1.249076
多元回归模型的回归系数: [ 0.85972339 56.85521851]
多元回归模型MSE:672.048805
```

Python实现线性回归结果图