

第4章 线性模型—逻辑回归

浙江理工大学 曹丽

办公室 10-541

为什么要学习逻辑回归模型？

逻辑回归模型是一种分类预测模型，由于其具有简单、易于解释等优点，成为了在实际应用中常被用到的机器学习模型之一。对于大数据从业者来说，逻辑回归是一个必须了解和掌握的模型之一。

银行业： 利用逻辑回归模型来构建违约概率模型，预测评估客户贷款的违约风险、客户信用评分等。

电信业： 根据电信业务的历史营销数据（营销成功与失败用户），利用逻辑回归模型来识别某项业务的潜在营销目标客户，例如5G潜在用户、潜在离网用户预测等。

医学： 经常用于研究发生某项疾病的风险，基于观察到的患者特征（年龄、性别、体重指数、各种检查结果等），利用逻辑回归模型来分析预测发生特定疾病（例如糖尿病，冠心病等）的风险。

逻辑回归的基本思想

我们先用一个最为熟悉的例子——高考上大学，来直观地理解下逻辑回归的基本思想。假设A同学今年参加了高考，分数也已经出来了，我们要来预测下A同学是否能够上浙江大学的录取线，通常会采用如下的思考和评估方法。

1. 找到去年高考成绩及浙大录取情况的数据

是否能上浙大 (y)	语文 (x ₁)	数学 (x ₂)	英语 (x ₃)	物理 (x ₄)	化学 (x ₅)	生物 (x ₆)	总分
是 (1)	135	140	138	98	95	94	700
是 (1)	130	136	128	95	90	90	669
否 (0)	110	115	120	86	80	80	591
...	...	...	...	...	...	...	...

- 语文、数学、英语等每一个学科，可以看成是一个自变量；是否上了浙大录取线可以看成是一个分类因变量。

2. 计算高考总分

$$\text{总分}(Z) = 1 * x_1 + 1 * x_2 + 1 * x_3 + 1 * x_4 + 1 * x_5 + 1 * x_6$$

- 各科成绩的总分可以看成是一个特殊的线性函数，每个自变量的系数为1。

3. 根据去年浙大录取情况，可以得到如下判断规则

$$\text{能否上浙大}(y) = \begin{cases} \text{总分}(Z) \geq 660 & \text{能}(Y=1) \\ \text{总分}(Z) < 660 & \text{不能}(Y=0) \end{cases}$$

- 通过对往年浙大录取分数的分析（相当于样本数据训练），很容易得到规则，总分在660分以上可以被浙大录取，低于660分则不能，通过这个规则可以将考生分为两类。

4. 根据今年的成绩来进行预测

如果A同学今年成绩是720分，那么我们判断他能上浙大；如果成绩是600分，那么判断他可能不能上浙大。

存在问题？


- (1) 进行分类的阈值不具有通用性；
- (2) 无法表示预测的大小。

逻辑回归的基本思想

我们再对这个例子做一下优化改进，在计算得到高考总分的基础上，将总分输入到sigmoid函数中，从而将原来取值范围为0—750的总分转换为0—1之间的值，越接近1表示考上浙大的可能性越高，从而解决了前面提到的两个问题。


1. 计算总分Z

$$\text{总分}(z) = 1 * x_1 + 1 * x_2 + 1 * x_3 + 1 * x_4 + 1 * x_5 + 1 * x_6$$



2. 将总分作为自变量，输入到Sigmoid函数

$$h(z) = \frac{1}{1 + e^{-z}}$$



3. 得到能否上浙大的概率值

$$\text{能否上浙大}(y) = \begin{cases} h(z) \geq 0.5 & \text{能}(Y=1) \\ h(z) < 0.5 & \text{不能}(Y=0) \end{cases}$$

- 如果分数是720分，则可能性可能达到0.9
- 如果分数是661，则可能性可能为0.51

逻辑回归与线性回归

线性回归模型是最简单的回归模型。假设自变量和因变量之间存在线性关系，但现实世界的数据的情况往往复杂得多，因此非线性回归模型的应用更为广泛一些。

逻辑回归是最常见的一种非线性回归。逻辑回归是一种可以用于分类的回归算法，多用于二分类任务。**即目标变量只有两个值的情况。例如需要预测“二选一”事件可能性（比如好用户还是坏用户，流失还是不流失）。**

逻辑回归


逻辑回归**是一种解决分类预测问题的机器学习方法**，通过找到一系列相关的影响因素，经过对样本数据的训练学习，为每个影响因素根据重要程度赋予不同的权重，根据这些因素的线性综合得分转化为预测某个分类的概率，从而实现对分类的预测。

在逻辑回归中，通过构建一个逻辑函数（Logistic function），将线性回归的结果转换为概率的形式，从而进行分类。区别于一般的线性回归，**逻辑回归计算每个样本介于0-1的概率值**。我们可以选择一个概率阈值，比如0.5，当概率大于0.5时，判定样本属于某一类，当概率小于或者等于0.5时，样本属于另外一类。

预测函数（Sigmoid函数）


需要找一个预测函数模型，使其输出为 $[0,1]$ ，然后选择一个基准值，如0.5。如果算出来的预测值大于0.5，就认为其预测值为1；反之，则其预测值为0。

选择Sigmoid函数 $h(z) = \frac{1}{1+e^{-z}}$ 来作为预测函数，其中 e 是自然对数的底数。以 z 作为横坐标，以 $h(z)$ 为纵坐标，Sigmoid函数图像如右图：



Sigmoid 函数曲线

预测函数（Sigmoid函数）的特征



Sigmoid 函数曲线

函数单调性递增： Sigmoid是一个单调递增函数，随着变量的增加函数取值单调递增。


函数取值在0-1之间： 函数当变量趋向无穷大时，函数趋向于1；当变量趋向于无穷小时，函数趋向于0；当变量为0时，函数处于中间值0.5.

中间变化快，两边平缓： Sigmoid函数在0和1附近变化比较平缓，中间变化迅速。

逻辑回归的表达形式


假设Y是二分类变量（取值0或者1），有d个影响因素 $x_1, x_2, \dots, x_d$ ，我们希望通过d个影响因素来预测样本属于某个分类（例如Y=1）的可能性（概率），那么用逻辑回归模型来预测的过程如下：

① 构建线性回归函数



$$z = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_d x_d = \theta^T x$$

② 输入到sigmoid函数



代入

$$h(z) = \frac{1}{1 + e^{-z}}$$

$$h_{\theta}(x) = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_d x_d)}} = \frac{1}{1 + e^{-\theta^T x}}$$

③ 得到Y=1的可能性（概率）

$$Y = \begin{cases} 1 & \text{当 } h(z) \geq 0.5 \text{ 时} \\ 0 & \text{当 } h(z) < 0.5 \text{ 时} \end{cases}$$


一般情况下当概率值大于0.5时判断为Y=1分类，当然也可以根据实际需要提高概率阈值

$$h_{\theta}(x) = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_d x_d)}} = \frac{1}{1 + e^{-\theta^T x}}$$

$h_{\theta}(x)$ 代表Y=1的概率，
即 $P(Y = 1, X)$

逻辑回归模型：需要解决的问题

逻辑回归模型的表达形式虽然简单，但在实际中，模型参数 θ 参数值事先是不知道的，需要我们利用样本数据来拟合得到。




两个问题：

- (1) 有一种方法来衡量模型预测结果与实际值的误差大小；
- (2) 有一种方法能够找到使得这种误差最小化的模型，即找到最佳的 θ 参数值。


逻辑回归模型：损失函数

单个样本的损失函数：
$$C(\theta) = \begin{cases} -\ln(h_{\theta}(x^{(i)})) & \text{当 } Y=1 \\ -\ln(1 - h_{\theta}(x^{(i)})) & \text{当 } Y=0 \end{cases}$$

当 $Y=1$ 的情况，损失函数为： $C(\theta) = -\ln(h_{\theta}(x^{(i)}))$




当 $Y=0$ 的情况，损失函数为： $C(\theta) = -\ln(1 - h_{\theta}(x^{(i)}))$



为什么说损失函数值越小，表示模型学习效果越好？

逻辑回归模型：损失函数的构造

极大似然估计提供了一种基于现有样本数据来评估模型参数的方法，**其核心思想是利用已知的样本结果，反向推算最有可能导致这样结果的参数值**，即寻找某组参数值使得样本数据出现的概率达到最大。逻辑回归模型损失函数可以通过极大似然估计方法推导得到。



逻辑回归模型：损失函数的构造

根据极大似然估计的思想，我们的目标是求得某个 θ ，从而让 $L(\theta)$ 取得最大值，即，使得这组样本数据出现的概率最大。

似然函数的通用化表达：

$$L(\theta) = \prod_{i=1}^n h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{(1-y^{(i)})}$$

逻辑回归模型：损失函数的构造

极大似然概率： $L(\theta) = \prod_{i=1}^n h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{(1-y^{(i)})}$

为方便计算，取对数：

$$\ln(L(\theta)) = \ln\left(\prod_{i=1}^n h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{(1-y^{(i)})}\right)$$

$$= \sum_{i=1}^n \ln\left(h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{(1-y^{(i)})}\right)$$

$$= \sum_{i=1}^n (\ln h_{\theta}(x^{(i)})^{y^{(i)}} + \ln(1 - h_{\theta}(x^{(i)}))^{(1-y^{(i)})})$$

$$= \sum_{i=1}^n [y^{(i)} \ln(h_{\theta}(x^{(i)})) + (1-y^{(i)}) \ln(1 - h_{\theta}(x^{(i)}))]$$

添加负号，从求最大概率值，转换为求最小值：

$$\min -\ln(L(\theta)) = -\sum_{i=1}^n [y^{(i)} \ln(h_{\theta}(x^{(i)})) + (1-y^{(i)}) \ln(1 - h_{\theta}(x^{(i)}))]$$



为了消除样本个数的影响除以样本数n：

$$C(\theta) = -\frac{1}{n} \sum_{i=1}^n [y^{(i)} \ln(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \ln(1 - h_{\theta}(x^{(i)}))]$$

逻辑回归模型：模型参数估计

在机器学习问题中，需要一个损失函数，通过求其最小值进行参数优化，问题变成了求以对数似然函数为**目标函数的最优化问题**。**对数似然函数取负数就可以作为逻辑回归的对数损失函数：**


逻辑回归学习中通常采用的方法是梯度下降法即拟牛顿法。



逻辑回归模型：梯度下降法

梯度下降法是一种非常经典的最优化算法，通过这种方法我们就能快速找到函数的最小值。

什么是梯度？ 梯度是一个向量，它表示某一函数在该点处的方向导数沿着该方向取得最大值。即函数在该点处沿着该方向（梯度的方向）变化最快，变化率最大。简而言之，梯度就是指在某一个点的导数，对于多元函数而言，梯度就是指在某一点的偏导数组成的向量。



逻辑回归模型：模型参数估计

似然函数：
$$L(\theta) = \prod_{i=1}^n h_{\theta}(x^{(i)})^{y^{(i)}} (1 - h_{\theta}(x^{(i)})^{(1-y^{(i)})})$$

对数似然函数：
$$L(\theta) = \sum_{i=1}^n [y^{(i)} \ln h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \ln(1 - h_{\theta}(x^{(i)}))]$$

$$= \sum_{i=1}^n [y^{(i)} \ln \frac{h_{\theta}(x^{(i)})}{1 - h_{\theta}(x^{(i)})} + \ln(1 - h_{\theta}(x^{(i)}))]$$

$$= \sum_{i=1}^n [(y^{(i)} \cdot \theta^T \cdot x^{(i)}) - \ln(1 + e^{\theta^T \cdot x^{(i)}})]$$

两边取负号，对所有样本取平均值，得到损失函数：

$$J(\theta) = -\frac{1}{n} \sum_{i=1}^n [(y^{(i)} \cdot \theta^T \cdot x^{(i)}) + \ln(1 + e^{\theta^T \cdot x^{(i)}})]$$

逻辑回归模型：模型参数估计

损失函数： $J(\theta) = -\frac{1}{n} \sum_{i=1}^n [(y^{(i)} \cdot \theta^T \cdot x^{(i)}) + \ln(1 + e^{\theta^T x^{(i)}})]$

求导：
$$\begin{aligned} \frac{\partial J}{\partial \theta} &= -\frac{1}{n} \sum_{i=1}^n [(y^{(i)} x^{(i)}) - \frac{x^{(i)} e^{\theta^T x^{(i)}}}{e^{\theta^T x^{(i)}} + 1}] \\ &= -\frac{1}{n} \sum_{i=1}^n [-\frac{e^{\theta^T x^{(i)}}}{e^{\theta^T x^{(i)}} + 1} + y^{(i)}] x^{(i)} \\ &= -\frac{1}{n} \sum_{i=1}^n [-\frac{e^{-\theta^T x^{(i)}} e^{\theta^T x^{(i)}}}{e^{-\theta^T x^{(i)}} (e^{\theta^T x^{(i)}} + 1)} + y^{(i)}] x^{(i)} \\ &= -\frac{1}{n} \sum_{i=1}^n [-\frac{1}{1 + e^{-\theta^T x^{(i)}}} + y^{(i)}] x^{(i)} \\ &= -\frac{1}{n} \sum_{i=1}^n [-h_{\theta}(x^{(i)}) + y^{(i)}] x^{(i)} \end{aligned}$$

逻辑回归模型：模型参数估计

梯度下降法（Gradient Descent）是逻辑回归模型中常用的优化算法之一，用于最小化损失函数，找到能够最小化损失函数的参数值 β 。

基本思想是：其基本思想是沿着损失函数的负梯度方向更新模型参数，逐步接近最优解。当得到梯度的方向，然后乘以一个常数 α ，就可以得到每次梯度下降的步长，最后，通过多次迭代，找到梯度变化很小的点，也就对应着损失函数的极小值了。

$$\theta = \theta - \alpha \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) x^{(i)}$$

逻辑回归模型：模型参数估计

优化过程：

1. 计算梯度：计算损失函数关于所有参数的梯度：

$$\nabla J(\theta) = \frac{\partial J(\theta)}{\partial \theta} = \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) x^{(i)}$$

将其转化成向量的形式：

$$\nabla J(\theta) = X^T ((h_{\theta}(X) - Y))$$

其中X 是包含所有样本特征的矩阵， θ 是参数向量， $h_{\theta}(X)$ 是所有样本的预测概率向量，Y是所有样本的实际标签向量。

因为 θ 和x维度相同，所以当x有n维的时候， θ 同样有n维，此时J (θ) 求导

也变成了对 θ 的每一个维度求导： $\frac{\partial J(\theta)}{\partial \theta} = \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) x^{(i)}$

逻辑回归模型：模型参数估计

优化过程：

2. 更新参数：根据梯度和学习率来更新每一个参数。学习率是一个超参数，它控制了每次更新参数的步长的大小。参数更新为：

$$\theta_j = \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j}$$

3. 重复迭代：

我们重复步骤1和2，直到满足某个停止条件。停止条件可以是：

- 梯度足够小
- 达到最大迭代次数
- 损失函数的值不再显著下降

逻辑回归模型案例

使用逻辑回归进行二分类

数据集：乳腺癌数据集是一个经典并且简单的二分类数据集。一共有569个样本，其中212个样本为恶性，357个样本为良性，每个样本有30个特征，均为非负实数。30个特征分为3类，前10个是相关指标的平均值，中间10个是指标的偏差，最后10个指标的最差极值。

要求：在分类的过程中，首先读取数据集，并将其随机分割成训练集和测试集，然后再训练集上采用逻辑回归的分类器，并在测试集上测试准确率，最后输出混淆矩阵。

逻辑回归小结

逻辑回归是一种典型的有监督分类算法，多用于解决二分类问题。逻辑回归虽然是个非线性模型，但它本质上却可以看成是线性回归与Sigmoid函数的结合。

传统的线性回归帮助我们拟合函数曲线的最佳参数，而Sigmoid函数帮助我们z把输出值固定在0~1。