

决策树算法

一、实验目的

- 1、掌握决策树算法的相关概念；
- 2、掌握决策树求解问题的流程；
- 3、能够编写出决策树算法预测问题的代码；
- 4、能够分析实验结果，对算法进行评估。

二、实验原理

决策树 (decision tree) 是一种常用的有监督算法，之所以名字带有“树”，因为其算法的实现过程类似于一棵树的生长过程，它从根部（根结点）开始，逐步到进行分支（内部结点），最终到一片片末端的树叶（叶结点）。在决策树里，所有的训练样本构成了根结点，每个内部节点对应一个特征（属性）测试，用来区分不同标签的样本。经过特征测试后，这个节点包含的所有样本根据特征测试的结果。决策树有一种“天然”高方差特征，会随着训练集的变化出现较大的变动，导致各模型对样本观测 X_0 的预测差异较大，表现出预测的高方差。

三、实验环境

Anaconda (支持 Python 3.7)，使用 Jupyter notebook 基于网页的交互性文本编辑器，安装 Numpy 库、Pandas 库、Matplotlib 库、Scikit-learn 库和可视化包 GraphViz。

四、实验内容及步骤

1、实验内容

(1) 用决策树模型预测在某种天气情况下，是否会出去运动？（训练数据：play.txt）构建决策树模型，并对决策树进行可视化，用 graphviz 将决策树呈现出来。分类决策树中有很多参数 (criterion, splitter, max_depth, min_samples_split, max_features) 分析这些参数对模型的影响？

(2) 用决策树模型预测泰坦尼克生还判断？（训练数据：train.csv、测试数据：test.csv），一个旅客是否能够逃生与他的 Pclass、Name、Sex、Age、SibSp、Parch、Ticket、Fare、Cabin、Embarked 等均有一定联系，能否找到这些特征和他们能否逃生之间的规律，选择对分类结果有关键作用的特征。构建决策树模型，并对决策树进行可视化，用 graphviz 将决策树呈现出来。

2、实验步骤

- (1) 导入 Numpy 库、Matplotlib 库、Pandas 库、Scikit-learn 库和 graphviz 包。
- (2) 导入 Scikit-learn 提供的决策树模块 DecisionTreeClassifier()
- (3) 使用 Pandas 库读取数据文件（数据清洗：数据类型转换、删除冗余数据等）
- (4) 构造决策树模型
- (5) 模型的评估和预测
- (6) 模型参数的选择、调整（选择最优参数）
- (7) 决策树的可视化、用 graphviz 将决策树呈现出来。

五、实验代码